

부산대학교
PUSAN NATIONAL UNIVERSITY

Derivatives and Probability

Derivatives and Probability

Local Change and Uncertainty in Model Fitting

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

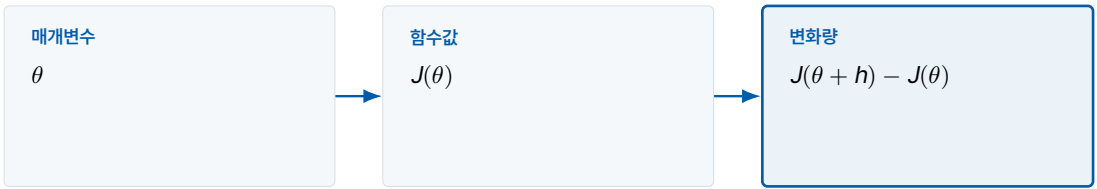
Section 1 • Derivatives and Probability

Local Change of a Function

매개변수의 작은 변화가 함수값에 미치는 영향

매개변수의 작은 변화

매개변수 θ를 h만큼 바꿀 때 함수값이 얼마나 달라지는지 확인한다



도함수(derivative)는 매개변수 변화에 대한 함수값의 국소 변화율이다

Source: Zhang et al. (2023), Derivatives and Differentiation.

함수값의 변화

실수 하나를 입력받아 실수 하나를 출력하는 함수부터 확인한다

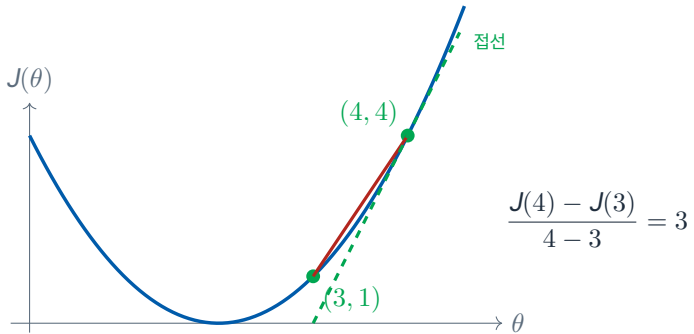
θ	$J(\theta) = (\theta - 2)^2$	$\theta - 2$
0	4	-2
2	0	0
4	4	2

$\theta = 2$에서 함수값이 가장 작고, 양쪽으로 멀어질수록 증가한다

Adapted from MIT 6.390 (2026), Matrix Calculus.

두 점을 잇는 직선의 기울기

$\theta = 3$과 $\theta = 4$ 사이에서 함수값이 변한 비율을 계산한다



두 점을 잇는 직선의 기울기(slope)는 두 점 사이의 평균변화율이다. 점선은 $\theta = 4$에서 곡선에 닿는 접선(기울기 4)이다

Source: Zhang et al. (2023), Derivatives and Differentiation.

간격을 줄이면

$\theta = 4$를 기준으로 다른 점을 가까이 옮기며 평균변화율을 비교한다

h	$J(4 + h)$	$\dfrac{J(4+h) - J(4)}{h}$	평균변화율
-1	$J(3) = 1$	$(1 - 4)/(-1)$	3
-0.5	$J(3.5) = 2.25$	$(2.25 - 4)/(-0.5)$	3.5
-0.1	$J(3.9) = 3.61$	$(3.61 - 4)/(-0.1)$	3.9
0.1	$J(4.1) = 4.41$	$(4.41 - 4)/0.1$	4.1

h가 양쪽에서 0에 가까워질수록 평균변화율은 4에 가까워진다

Source: Zhang et al. (2023), Derivatives and Differentiation.

도함수의 정의

간격 h를 0으로 줄인 극한이 한 점에서의 변화율이다

$$J'(\theta) = \lim_{h \to 0} \frac{J(\theta + h) - J(\theta)}{h}$$

기호	뜻
h	매개변수에 더하는 작은 변화
$J(\theta + h) - J(\theta)$	함수값의 변화
$J'(\theta)$	θ에서의 국소 변화율. 두 점을 잇는 직선이 $h \to 0$에서 가까워지는 접선의 기울기

Source: Zhang et al. (2023), Derivatives and Differentiation.

도함수의 부호와 변화 방향

작은 h에서 $J(\theta + h) - J(\theta) \approx J'(\theta)h$(1차 근사)로 증가와 감소를 판단한다

$J'(\theta) < 0$

θ를 늘리면 J가 감소

$J'(\theta) = 0$

1차 근사에서 변화가 없음

$J'(\theta) > 0$

θ를 늘리면 J가 증가

부호는 함수값이 늘어나는지 줄어드는지를, 절댓값은 같은 작은 변화에 함수값이 얼마나 크게 변하는지를 나타낸다

Source: Zhang et al. (2023), Derivatives and Differentiation.

기본 미분 공식

규칙	함수	도함수	적용하는 항
상수	c	0	고정된 항
거듭제곱	θ^n	$n\theta^{n-1}$	거듭제곱 항
합	$f + g$	$f' + g'$	여러 항의 합
상수배	$cf(\theta)$	$cf'(\theta)$	계수가 붙은 항

합으로 이루어진 식은 각 항에 미분 공식을 적용하여 계산한다

Source: Zhang et al. (2023), Derivatives and Differentiation.

이차함수를 미분한다

식을 펼친 뒤 거듭제곱과 합의 미분 공식을 적용한다

$$
\begin{aligned}
J(\theta) &= (\theta - 2)^2 = \theta^2 - 4\theta + 4 \\
J'(\theta) &= 2\theta - 4 = 2(\theta - 2) \\
J'(4) &= 2(4 - 2) = 4 \\
J'(1) &= 2(1 - 2) = -2
\end{aligned}
$$

> $\theta = 4$에서는 θ를 조금 줄이고, $\theta = 1$에서는 조금 늘리면 함수값이 감소한다

Adapted from MIT 6.390 (2026), Matrix Calculus.

Checkpoint

Local Change of a Function

- $J'(0)$, $J'(2)$, $J'(4)$의 값은 각각 얼마인가
- 각 점에서 θ를 어느 쪽으로 움직여야 J가 감소하는가
- $J'(2) = 0$은 1차 근사에서 무엇을 뜻하는가

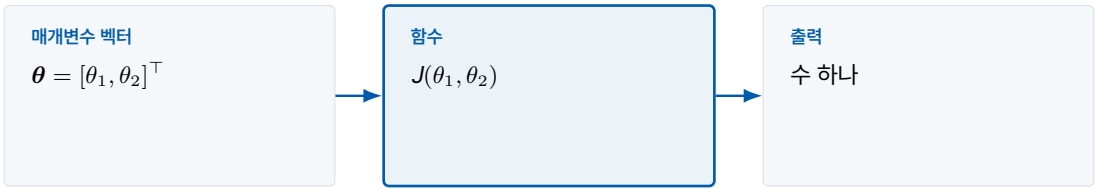
Section 2 • Derivatives and Probability

Multivariable Gradients

편미분을 모아 그래디언트를 구성

매개변수가 둘인 함수

J는 벡터(vector)를 입력받아 수 하나를 출력한다



매개변수가 여러 개이면 각 좌표 방향의 변화율을 따로 계산한다

Adapted from MIT 6.390 (2026), Matrix Calculus.

한 좌표만 바꾼다

다른 좌표는 고정하고 한 좌표에만 h를 더한다

변화 방향	바꾼 입력	고정한 값
θ_1 방향	$(\theta_1 + h, \theta_2)$	θ_2
θ_2 방향	$(\theta_1, \theta_2 + h)$	θ_1

편미분(partial derivative)은 다른 좌표를 고정하고 한 좌표만 바꿀 때 함수값이 변하는 비율이다

Source: Zhang et al. (2023), Partial Derivatives and Gradients.

좌표별 편미분

$J(\theta_1, \theta_2) = (\theta_1 - 2)^2 + \theta_2^2$**를 좌표별로 미분한다**

$$\frac{\partial J}{\partial \theta_1} = 2(\theta_1 - 2)$$
$$\frac{\partial J}{\partial \theta_2} = 2\theta_2$$

> 미분하지 않는 좌표는 상수로 둔다

Source: Zhang et al. (2023), Partial Derivatives and Gradients.

그래디언트는 편미분을 모은 벡터

각 매개변수에 대한 편미분을 매개변수와 같은 순서로 쌓은 벡터가 그래디언트(gradient)

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \begin{bmatrix} \dfrac{\partial J}{\partial \theta_1} \\ \dfrac{\partial J}{\partial \theta_2} \end{bmatrix} = \begin{bmatrix} 2(\theta_1 - 2) \\ 2\theta_2 \end{bmatrix}$$

> 그래디언트의 각 성분은 해당 매개변수에 대한 함수값의 국소 변화율이다

Source: MIT 6.390 (2026), Matrix Calculus.

그래디언트와 매개변수의 모양

입력	출력	미분 결과	모양
수 θ	수 J	$dJ/d\theta = J'(\theta)$	수 하나
벡터 $\boldsymbol{\theta}$	수 J	$\nabla_{\boldsymbol{\theta}} J$	$\boldsymbol{\theta}$와 같다
행렬 Θ	수 J	$\nabla_{\Theta} J$	Θ와 같다

수 하나를 출력하는 함수의 그래디언트는 매개변수와 같은 모양이다

Source: MIT 6.390 (2026), Matrix Calculus.

두 변수 이차함수

$\boldsymbol{\theta} = (4, 1)$에서 그래디언트를 계산한다

$$J(4,1) = (4-2)^2 + 1^2 = 5$$
$$\nabla J(4,1) = \begin{bmatrix} 2(4-2) \\ 2(1) \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$

θ_1 방향의 변화율 절댓값이 θ_2 방향보다 크다

Adapted from MIT 6.390 (2026), Matrix Calculus.

중앙차분으로 그래디언트를 확인한다

중앙차분(central difference)은 한 좌표의 양쪽 함수값 차를 2ε로 나누어 편미분을 근사한다

$$d_j = \frac{J(\boldsymbol{\theta} + \varepsilon \mathbf{e}_j) - J(\boldsymbol{\theta} - \varepsilon \mathbf{e}_j)}{2\varepsilon}, \qquad \mathbf{e}_j = j\text{번째 성분만 1인 벡터}$$

바꾼 좌표	앞쪽 함수값	뒤쪽 함수값	d_j
θ_1	$J(4.1, 1) = 5.41$	$J(3.9, 1) = 4.61$	4
θ_2	$J(4, 1.1) = 5.21$	$J(4, 0.9) = 4.81$	2

J가 이차함수라 $\varepsilon = 0.1$에서도 $(d_1, d_2) = (4, 2)$로 오차가 없다

대칭이 아닌 행렬의 이차함수

행렬의 두 비대각 원소가 한 교차항에 함께 들어간다

$$A = \begin{bmatrix} 2 & 1 \\ 3 & 4 \end{bmatrix}, \quad \boldsymbol{\theta} = \begin{bmatrix} u \\ v \end{bmatrix}, \quad \boldsymbol{b} = \mathbf{0}$$

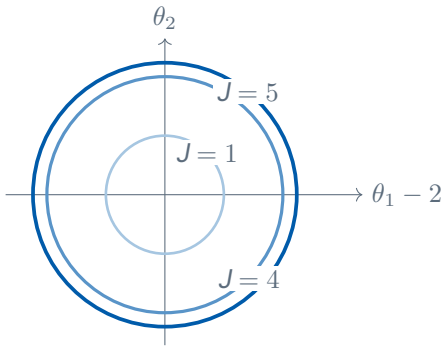
$$q(\boldsymbol{\theta}) = \tfrac{1}{2}\boldsymbol{\theta}^\top A\boldsymbol{\theta} + \boldsymbol{b}^\top\boldsymbol{\theta} = \tfrac{1}{2}\left(2u^2 + (1+3)uv + 4v^2\right) = u^2 + 2uv + 2v^2$$

$$\nabla q = \begin{bmatrix} 2u + 2v \\ 2u + 4v \end{bmatrix} = \frac{A + A^\top}{2}\boldsymbol{\theta} + \boldsymbol{b}, \qquad \nabla q(1, 2) = \begin{bmatrix} 6 \\ 10 \end{bmatrix}$$

> A가 대칭이 아니면 $A\boldsymbol{\theta}$만으로는 그래디언트를 구할 수 없다

같은 함수값을 잇는 등고선

J 값이 같은 점 (θ_1, θ_2)를 이은 선이 등고선(contour)이다

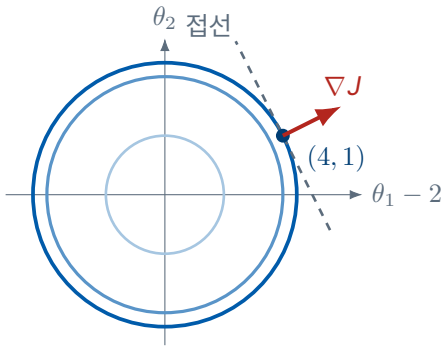


안쪽부터 $J = 1, 4, 5$인 등고선이며 중심 $\boldsymbol{\theta} = (2, 0)$에서 멀수록 J가 크다

Adapted from Zhang et al. (2023), Geometry of Gradients and Gradient Descent.

그래디언트와 등고선

$\theta = (4, 1)$에서 그래디언트 방향을 등고선 위에 표시한다



그래디언트는 등고선의 접선과 직교하며 함수값이 가장 빠르게 증가하는 방향이다

Adapted from Zhang et al. (2023), Geometry of Gradients and Gradient Descent.

작은 변화의 근사

$\Delta\theta$가 작을 때 내적으로 함수값의 변화를 근사한다

$$\Delta J \approx \nabla J(4,1)^\top \Delta\boldsymbol{\theta}$$
$$\nabla J(4,1) = [4,2]^\top$$
$$\Delta\boldsymbol{\theta} = [-0.2,-0.1]^\top$$
$$\Delta J \approx 4(-0.2) + 2(-0.1) = -1.0$$
$$\text{실제 } J(3.8,0.9) - J(4,1) = 4.05 - 5 = -0.95$$

그래디언트와 반대 방향으로 조금 이동하면 1차 근사에서 함수값이 감소한다

Source: MIT 6.390 (2026), Matrix Calculus.

Checkpoint

Multivariable Gradients

- $\boldsymbol{\theta} = (4, -1)$에서 그래디언트는 무엇인가
- 두 좌표 가운데 변화율의 절댓값이 큰 쪽은 어디인가
- J를 감소시키는 작은 변화 $\Delta\boldsymbol{\theta}$의 예는 무엇인가

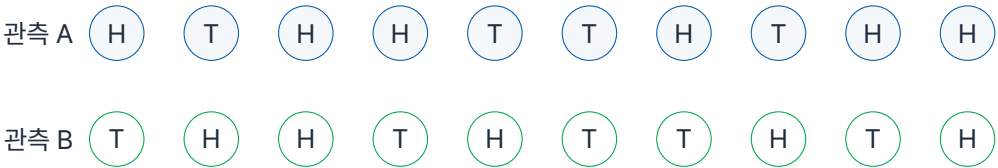
Section 3 • Derivatives and Probability

Uncertainty in Observations

표본공간, 사건, 확률변수, 통계량의 구분

같은 시행, 다른 결과

같은 조건에서 동전을 열 번씩 던져도 결과는 매번 달라질 수 있다

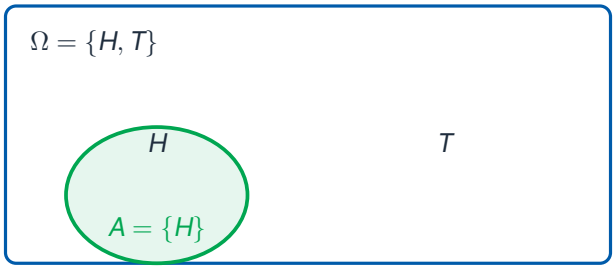


관측 A는 앞면이 6번, 관측 B는 5번 나와 순서와 개수가 모두 다르다

Adapted from Zhang et al. (2023), A Simple Example: Tossing Coins.

표본공간과 사건

표본공간(sample space)은 가능한 결과 전체이고, 사건(event)은 그 부분집합이다



$\Omega = \{H, T\}$에서 사건 $A = \{H\}$는 앞면이 나오는 경우이다

Adapted from Zhang et al. (2023), A More Formal Treatment.

확률분포의 기본 규칙

확률분포(probability distribution)는 가능한 결과에 확률을 배정한다

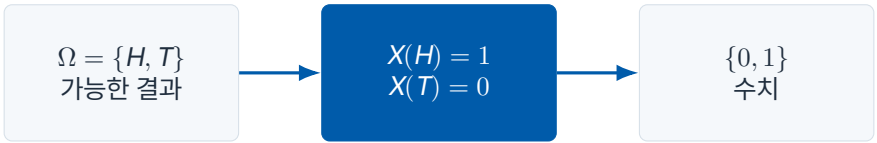
조건	식	동전 예
0 이상	$P(\omega) \geq 0$	$P(H), P(T) \geq 0$
전체 확률	$\sum_{\omega \in \Omega} P(\omega) = 1$	$P(H) + P(T) = 1$
사건의 확률	$P(A) = \sum_{\omega \in A} P(\omega)$	$P(\{H\}) = P(H)$

> 가능한 모든 결과에 배정한 확률의 합은 1이다

Source: Zhang et al. (2023), A More Formal Treatment.

확률변수는 결과를 수로 바꾼다

확률변수(random variable)는 각 결과에 수 하나를 대응시킨다



확률변수 X는 앞면을 1, 뒷면을 0으로 바꾸는 함수이다

Adapted from Zhang et al. (2023), Random Variables.

베르누이 확률변수

베르누이(Bernoulli) 확률변수는 두 결과를 0과 1로 기록한다

결과	X	확률	매개변수
H	1	p	$P(X=1)=p$
T	0	$1-p$	$P(X=0)=1-p$

베르누이 분포의 매개변수 p는 $X=1$이 될 확률이다

Source: Zhang et al. (2023), Random Variables.

동전을 열 번 던진 결과

앞면을 1, 뒷면을 0으로 기록한 열 번의 관측값을 사용한다



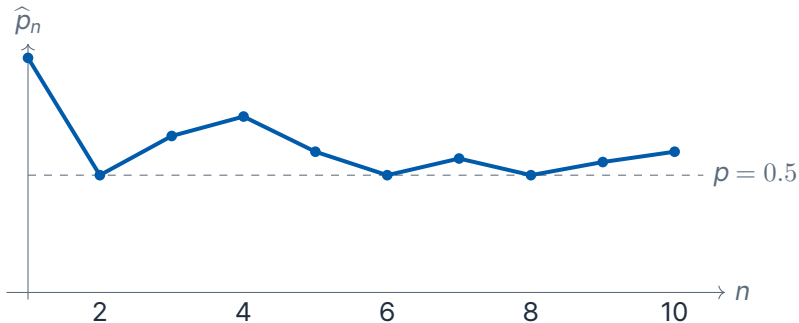
$$\sum_{i=1}^{10} X_i = 6 \qquad \hat{p} = \bar{X} = \frac{6}{10} = 0.6$$

표본평균(sample mean)은 앞면의 상대도수 $6/10 = 0.6$과 같다

Adapted from Zhang et al. (2023), A Simple Example: Tossing Coins.

상대도수로 확률을 추정한다

시행 수 n에 따라 누적 상대도수 $\hat{p}_n$이 어떻게 변하는지 확인한다



시행 횟수가 적을 때는 한 번의 결과가 추정값에 미치는 영향이 크다

Adapted from Zhang et al. (2023), A Simple Example: Tossing Coins.

매개변수와 통계량

대상	기호	뜻
매개변수	p	시행 과정의 확률, 직접 관측되지 않음
관측값	X_i	한 번의 시행에서 기록한 0 또는 1
통계량	$\widehat{p}_n = \bar{X}_n$	n개 관측값으로 계산한 추정값

매개변수는 확률분포의 속성이고, 통계량은 관측 자료에서 계산한 값이다

Source: Zhang et al. (2023), A Simple Example: Tossing Coins.

Checkpoint

Uncertainty in Observations

- 동전 던지기의 표본공간과 사건 $\{H\}$는 무엇인가
- 확률변수 X는 각 결과에 어떤 수를 대응시키는가
- 매개변수 p와 통계량 $\hat{p}_{10}$은 어떻게 다른가

Section 4 • Derivatives and Probability

Expectation and Variance

기댓값과 분산으로 확률분포를 요약

기댓값은 확률 가중평균

기댓값(expectation)은 각 값과 그 확률의 곱을 모두 더한 분포의 중심이다

$$\mathbb{E}[X] = \sum_{x} xP(X = x)$$

x	확률변수 X가 가질 수 있는 값
$P(X = x)$	값 x가 나타날 확률
$xP(X = x)$	값 x가 기댓값에 기여하는 양

Source: Zhang et al. (2023), Probability and Statistics: Expectations.

기댓값 계산 예

세 값에 각각의 확률을 곱한 뒤 모두 더한다

x	$P(X = x)$	$xP(X = x)$
-1	0.25	-0.25
0	0.50	0
3	0.25	0.75
	합계	0.50

베르누이 확률변수의 기댓값은 $\mathbb{E}[X] = 1 \cdot p + 0 \cdot (1 - p) = p$이다

> 기댓값 0.5는 분포의 중심이며 실제로 가능한 값일 필요는 없다

Source: Zhang et al. (2023), Probability and Statistics: Expectations.

분산은 제곱편차의 기댓값

분산(variance)은 각 값이 기댓값에서 떨어진 정도를 제곱한 값의 기댓값이다

$$\begin{aligned}\mathrm{Var}(X) &= \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] \\ &= \mathbb{E}[X^2] - \mathbb{E}[X]^2\end{aligned}$$

편차	$X - \mathbb{E}[X]$
제곱편차	부호를 없애고 큰 차이를 더 크게 반영
분산	제곱편차의 기댓값

앞의 분포에서 $\mathbb{E}[X^2] = 2.5$이므로 $\mathrm{Var}(X) = 2.5 - 0.5^2 = 2.25$

Source: Zhang et al. (2023), Probability and Statistics: Expectations.

기댓값이 같아도 분산은 다를 수 있다

두 분포의 기댓값은 모두 0이지만 값이 퍼진 정도는 다르다



기댓값만으로 분포의 퍼진 정도를 구분할 수 없다

Adapted from Zhang et al. (2023), Random Variables: Variances.

표준편차

표준편차(standard deviation)는 분산의 제곱근으로 원자료와 단위가 같다

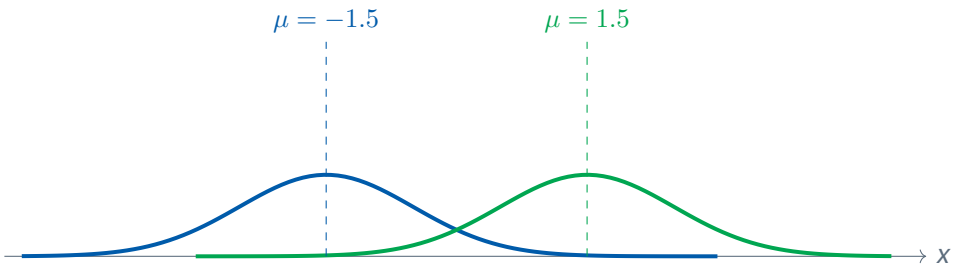
요약값	정의	단위
기댓값(평균 μ)	$\mu = \mathbb{E}[X]$	X와 같음
분산	$\sigma^2 = \mathrm{Var}(X)$	X 단위의 제곱
표준편차	$\sigma = \sqrt{\mathrm{Var}(X)}$	X와 같음

> 표준편차는 값이 퍼진 정도를 원자료와 같은 단위로 나타낸다

Source: Zhang et al. (2023), Random Variables: Standard Deviations.

가우스 분포의 평균

가우스 분포(Gaussian distribution)에서 분산을 고정하고 평균만 바꾸면 곡선의 중심이 이동한다

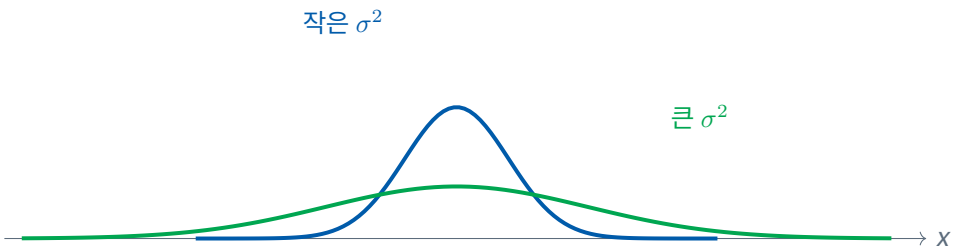


두 곡선은 모양이 같고 중심만 -1.5와 1.5로 다르다

Adapted from Zhang et al. (2023), Distributions: Gaussian.

가우스 분포의 분산

평균을 고정하고 분산을 바꾸면 곡선이 퍼진 정도가 달라진다

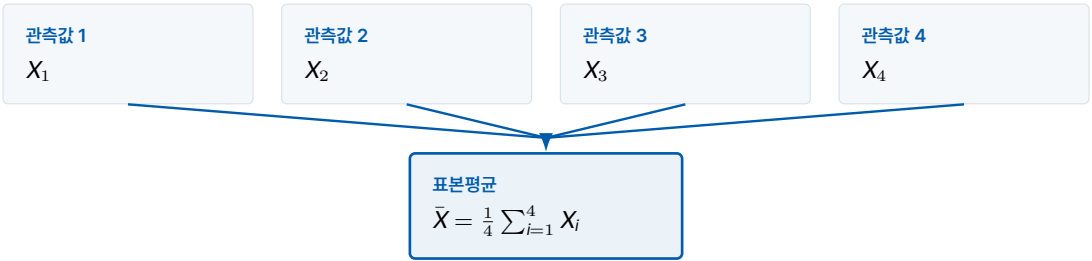


분산이 클수록 확률밀도 곡선이 넓게 퍼지고, 곡선 아래 넓이가 확률이므로 두 곡선의 전체 넓이는 모두 1이다

Adapted from Zhang et al. (2023), Distributions: Gaussian.

표본평균에서 한 관측값의 비중

관측값 네 개를 평균하면 각 관측값의 계수는 $1/4$이다



관측값 하나가 δ만큼 변하면 표본평균은 $\delta/4$만큼 변한다

Source: Zhang et al. (2023), Random Variables: Variances.

표본평균의 분산

$X_1, \ldots, X_n$이 서로 독립이고 분산이 모두 σ^2인 경우이다

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

$$\operatorname{Var}(\bar{X}) = \frac{1}{n^2}\operatorname{Var}\left(\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\operatorname{Var}(X_i) = \frac{\sigma^2}{n}$$

$1/n^2$은 $\operatorname{Var}(cX) = c^2\operatorname{Var}(X)$에서, 합의 분산이 분산의 합이 되는 것은 서로 독립이라는 조건에서 나온다

> 서로 독립인 관측값 n개의 표본평균의 분산은 개별 관측값 분산의 $1/n$배이다

Source: Zhang et al. (2023), Random Variables: Variances.

함수의 국소 변화와 자료의 변동

개념	설명하는 대상	요약
도함수	한 매개변수의 변화	함수값의 국소 변화율
그래디언트	매개변수 벡터의 변화	좌표별 국소 변화율 벡터
기댓값	확률분포의 중심	확률 가중평균
분산	중심 주변의 변동	제곱편차의 기댓값

> 도함수와 그래디언트는 함수의 국소 변화를, 기댓값과 분산은 분포의 중심과 퍼짐을 나타낸다

Checkpoint

Expectation and Variance

- x와 $P(X = x)$로 기댓값을 계산하는 식은 무엇인가
- 분산과 표준편차의 단위는 어떻게 다른가
- 서로 독립인 관측값의 표본평균의 분산이 σ^2/n인 이유는 무엇인가

Why Does a Model Fit Training Data but Fail on New Data?

Next Lecture: Learning and Generalization

- 학습 자료와 새 자료에서의 성능
- 과적합의 의미
- 편향과 분산

오용경 yongkyung.oh@pusan.ac.kr