



부산대학교

PUSAN NATIONAL UNIVERSITY

Learning and Generalization

Learning and Generalization

Why Training Error Is Not Enough

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공


yongkyung.oh@pusan.ac.kr

Section 1 • Learning and Generalization

Training Data and Test Data

자료를 둘로 나누는 이유

학습한 자료와 새 자료



자료에 맞추는 것과 새 자료를 맞추는 것은 다른 문제

같은 모델을 두 자료에서 평가

자료	학습에 사용했는가	확인할 수 있는 것
학습에 쓴 관측	예	그 자료에 맞춘 정도
학습에 쓰지 않은 관측	아니요	새 자료에서의 성능

DEFINITION

학습 자료(training data)

매개변수(parameter)를 정하는 데 쓰는 관측

DEFINITION


테스트 자료(test data)

학습과 모델 선택에 쓰지 않고 최종 성능 평가에 사용하는 자료

테스트 자료를 학습이나 모델 선택에 사용하면 최종 평가의 독립성이 깨진다

자료를 나누는 순서

학습·테스트 분할(train-test split)은 모델을 만들기 전에 한다



먼저 나누고 학습 자료만 보면서 모델을 정한다

두 오차를 MSE로 계산

예측 오차(prediction error)를 평균제곱오차(mean squared error, MSE)로 잰다

$$\text{MSE}_{\text{train}} = \frac{1}{n_{\text{train}}} \sum_{i \in \text{train}} (y^{(i)} - \hat{f}(x^{(i)}))^2$$

학습 오차

학습 자료에서 계산한 $\text{MSE}_{\text{train}}$

$$\text{MSE}_{\text{test}} = \frac{1}{n_{\text{test}}} \sum_{i \in \text{test}} (y^{(i)} - \hat{f}(x^{(i)}))^2$$


테스트 오차

테스트 자료에서 계산한 MSE_{test}

두 식의 형태는 같고, 평균을 내는 관측만 다르다

학습 오차가 새 자료의 오차를 과소 추정하는 이유

학습 오차를 재는 관측에는 모델이 이미 맞춰져 있다



학습 오차만 사용하면 새 자료의 오차를 과소 추정하기 쉽다

Checkpoint

Training Data and Test Data

- 학습 자료와 테스트 자료는 각각 어디에 쓰는가
- 두 MSE 식에서 달라지는 것은 무엇인가
- 학습·테스트 분할을 적합보다 먼저 하는 이유는 무엇인가

Error Decomposition

예측 오차에서 줄일 수 있는 부분과 남는 부분

관측값은 함수와 잡음의 합

입력이 같아도 Y 값이 달라지는 상황을 식으로 나타낸다

$$Y = f(X) + \varepsilon, \quad \varepsilon \text{은 } X \text{와 독립이고 } \mathbb{E}(\varepsilon) = 0$$

$f(X)$

X 가 주어졌을 때 Y 의
조건부 기댓값(conditional expectation)

ε

측정되지 않은 요인과 우연한 흔들림

같은 X 에서도 ε 때문에 Y 가 달라질 수 있다

가장 좋은 예측

제곱 오차의 기댓값을 가장 작게 만드는 함수는 조건부 기댓값 f

$$f(x) = \mathbb{E}(Y \mid X = x)$$

뜻

$X = x$ 일 때 Y 의 기댓값. 앞 쪽의 $f(X)$ 와 같은 대상

학습 목표

모델로 이 함수 f 를 추정

오차를 둘로 가른다

학습을 마친 $\hat{f}$ 와 입력 x 를 고정하고 잡음 ε 에 대해서만 기댓값을 낸 제곱 오차

$$\mathbb{E}[(Y - \hat{f}(X))^2 \mid X = x] = \underbrace{[f(x) - \hat{f}(x)]^2}_{\text{줄일 수 있는 오차}} + \underbrace{\text{Var}(\varepsilon)}_{\text{줄일 수 없는 오차}}$$

$(f(x) - \hat{f}(x) + \varepsilon)^2$ 을 펼치면 $\mathbb{E}(\varepsilon) = 0$ 이라 교차항이 사라지고 $\mathbb{E}(\varepsilon^2) = \text{Var}(\varepsilon)$ 이 남는다

줄일 수 있는 오차

모델을 바꾸어 줄일 수 있는 부분(reducible error)

줄일 수 없는 오차

f 를 정확히 알아도 남는 부분(irreducible error)

$\text{Var}(\varepsilon) > 0$ 이면 제곱 예측 오차의 기댓값은 0이 될 수 없다

Checkpoint

Error Decomposition

- $Y = f(X) + \varepsilon$ 에서 두 항은 각각 무엇을 뜻하는가
- 모델을 바꾸어 줄일 수 있는 오차는 어느 항인가
- f 를 정확히 알아도 오차가 남는 이유는 무엇인가


Section 3 • Learning and Generalization

Flexibility and Error


모델 복잡도에 따라 달라지는 두 오차

모델 복잡도

모델 복잡도(model complexity)는 모델이 표현할 수 있는 관계의 폭



세 적합과 두 오차



왼쪽 검은 곡선은 참 함수, 세 색 곡선은 복잡도가 다른 적합이다. 오른쪽 회색, 빨간색은 학습-테스트 MSE, 점선은 줄일 수 없는 오차 $\text{Var}(\epsilon)$ 이다

Source: James et al. (2023), Figure 2.9.

두 곡선이 다르게 움직인다

그림의 가로축 Flexibility가 모델 복잡도를 뜻한다


복잡도	학습 오차	테스트 오차
높일수록	계속 줄어든다	줄다가 다시 커진다
너무 낮을 때	크다	크다
너무 높을 때	가장 작아진다	다시 커진다

과하게 맞춘 상태

DEFINITION


과적합(overfitting)

학습 자료의 잡음까지 따라가 학습 오차는 작지만 새 자료의 오차는 덜 복잡한 모델보다 커진 상태



Source: James et al. (2023), Section 2.2.2.

참 관계가 단순하면 최저점이 낮은 복잡도로 옮겨 간다



참 함수가 선형에 가까우면 테스트 오차의 최저점이 더 낮은 복잡도에서 나타난다

Source: James et al. (2023), Figure 2.10.

일반화

DEFINITION

일반화(generalization)

새로 관측할 자료에서 기대되는 모델의 성능

재는 값


테스트 자료의 오차

알고 싶은 값

앞으로 만날 모든 자료의 오차

테스트 오차는 일반화 성능의 추정값이지 그 자체가 아니다

복잡도를 올리면 잃는 것



복잡도가 높을수록 더 다양한 관계를 적합하지만 결과를 설명하기는 어려워진다

Adapted from James et al. (2023), Figure 2.7.

모델 복잡도의 맞바꿈

맞바꿈	내용
정확도와 해석 가능성	복잡한 모델일수록 예측의 이유를 설명하기 어렵다
알맞은 적합과 과적합	어느 정도가 알맞은지는 학습 오차만으로 알 수 없다

Source: James et al. (2023), Section 2.1.3.

관측 수와 모델 복잡도

같은 복잡도라도 n 이 크면 흔들림이 줄어든다

상황	검토할 복잡도	이유
관측이 적다	낮은 복잡도부터 검토	복잡한 모델이 잡음을 따라가기 쉽다
관측이 많다	더 높은 복잡도도 검토	추정이 덜 흔들린다

자주 하는 실수

주장	놓친 점
학습 오차가 0이니 완성이다	새 자료에서 재지 않았다
테스트 오차가 크니 자료를 더 모으자	구조적 편향이 크면 자료만 늘려서는 오차가 충분히 줄지 않을 수 있다
복잡한 모델이 늘 낫다	참 관계가 단순하면 단순한 모델이 낫다

두 오차를 함께 보지 않으면 어떤 문제인지 진단할 수 없다

복잡도를 조절하는 요소는 모델마다 다르다

모델	복잡도를 정하는 요소	복잡도가 달라지는 방식
다항 회귀	차수	차수가 높을수록 복잡하다
의사결정나무	나무의 깊이	나무가 깊을수록 복잡하다
신경망	층과 노드의 수	층·노드가 많을수록 복잡하다

Checkpoint

Flexibility and Error

- 복잡도를 올릴 때 학습 오차는 어떻게 되는가
- 테스트 오차가 다시 커지는 이유는 무엇인가
- 과적합은 무엇을 따라간 결과인가

Section 4 • Learning and Generalization

Bias and Variance

테스트 오차가 U자를 그리는 이유

빗나가는 방식이 둘이다

같은 크기의 오차라도 원인은 다를 수 있다

DEFINITION

편향(bias)

참 관계보다 단순한 모델의 구조적 오차

DEFINITION

분산(variance)

학습 자료가 바뀌면 적합이 흔들리는 정도

Source: James et al. (2023), Section 2.2.2.

테스트 오차의 분해


학습 자료를 새로 뽑아 여러 번 학습했을 때 x_0 에서 낸 평균 제곱 오차

$$\mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{분산}} + \underbrace{[\text{Bias}(\hat{f}(x_0))]^2}_{\text{편향의 제곱}} + \underbrace{\text{Var}(\varepsilon)}_{\text{줄일 수 없는 오차}}$$

$\text{Bias}(\hat{f}(x_0)) = \mathbb{E}[\hat{f}(x_0)] - f(x_0)$. 기댓값과 분산은 학습 자료를 바꿔 가며 얻은 $\hat{f}(x_0)$ 에 대한 것

세 항이 모두 0 이상이므로 테스트 오차의 기댓값은 $\text{Var}(\varepsilon)$ 보다 작아질 수 없다

복잡도에 따라 두 항이 엇갈린다



파란 편향의 제공은 줄고 주황 분산은 커지며, 빨간 테스트 MSE는 두 항과 점선의 줄일 수 없는 오차를 더한 값이다

Source: James et al. (2023), Figure 2.12.

두 오차로 본 증상과 원인

증상	학습 오차	새 자료의 오차	원인
덜 맞춤	크다	크다	편향
과하게 맞춤	매우 작다	크다	분산
알맞음	작다	가장 작다	두 원인의 균형

DEFINITION

과소적합(underfitting)

모델이 참 관계보다 단순해 학습 자료의 관계조차 담지 못한 상태

과소적합

두 오차가 모두 크다

과적합

학습 오차는 작고, 복잡도를 낮추면 새 자료의 오차가 줄어든다

두 오차로 진단하기

두 오차를 나란히 놓고 읽는다

학습 오차가 크다

편향이 클 수 있다. 잡음이
커도 두 오차가 함께 크다

학습 오차만 작다

같은 분포에서 나눈 자료라면
분산이 큰 경우

둘 다 작다

후보 가운데 적절한 복잡도

복잡도는 학습에 쓰지 않은 자료의 오차로 고르며, 최종 평가용 테스트 자료는 선택에 쓰지 않는다

범주를 맞추는 문제의 오류율

오류율(error rate)은 전체 관측 중 잘못 분류한 비율

$$\text{Err}_{\text{test}} = \frac{1}{n_{\text{test}}} \sum_{i \in \text{test}} I(y^{(i)} \neq \hat{C}(x^{(i)}))$$

$I(\cdot)$

틀리면 1, 맞으면 0

$\hat{C}(x)$

모델이 예측한 범주

MSE 대신 오류율을 써도 학습 자료와 테스트 자료를 나누는 원칙은 같다

테스트 자료를 반복해서 볼 때


테스트 결과를 보고 모델을 고칠수록 그 자료에도 맞춰진다

쟁점	내용
나누는 비율	테스트 자료가 적으면 추정이 흔들린다
나눈 결과	어떤 관측이 들어갔는지에 따라 값이 달라진다
반복 사용	테스트 결과를 보고 고치면 독립 평가가 아니다

테스트 자료는 학습과 모델 선택에 쓰지 않고 최종 성능 평가에 남긴다

새 자료에서 틀리는 이유

학습한 자료에서 잘 맞는 모델도 새 자료에서는 틀릴 수 있다



분산이 커지는 조건

학습 자료가 조금 달라졌을 때 적합이 크게 바뀌는 조건

조건	적합에 미치는 영향
관측이 적다	관측 하나가 바뀌어도 추정 결과가 크게 달라진다
모델이 매우 복잡하다	각 관측의 작은 차이까지 관계로 따라간다
관측 잡음이 크다	학습 자료가 바뀔 때 따라갈 모양도 크게 달라진다

분산은 모델 복잡도, 관측 수, 잡음의 크기에 함께 좌우된다

세 곡선을 함께 읽는다

복잡도	주된 원인	두 오차의 모습
낮음	편향이 큼	학습 오차와 테스트 오차가 모두 큼
중간	두 항의 균형	테스트 오차가 가장 작음
높음	분산이 큼	학습 오차는 작고 테스트 오차는 다시 큼

알맞은 복잡도는 새 자료의 오차가 가장 작은 곳이며, 고를 때는 최종 테스트 자료가 아니라 학습에 쓰지 않은 다른 자료로 그 오차를 잴다

성능을 말할 때 함께 밝힐 것

숫자 하나만으로는 읽는 사람이 판단할 수 없다

함께 밝힐 정보	밝히지 않았을 때의 오해
평가에 사용한 자료	학습 오차를 일반화 성능으로 해석한다
테스트 관측 수	변동성이 큰 추정치를 안정적이라고 판단한다
모델을 비교한 횟수	테스트 자료로 모델을 고른 사실이 드러나지 않는다

성능은 값 하나가 아니라 재는 방법과 함께 보고한다

용어	뜻
학습 자료	매개변수를 정하는 데 쓰는 관측
테스트 자료	학습·모델 선택에 쓰지 않고 최종 성능을 평가하는 자료
적합	모델을 자료에 맞추는 과정
일반화	새로 관측할 자료에서 기대되는 성능
편향	참 관계보다 단순해서 구조적으로 빗나가는 정도
분산	학습 자료가 바뀔 때 흔들리는 정도

Checkpoint

Bias and Variance

- 편향이 큰 모델은 어떤 증상을 보이는가
- 분산이 큰 모델은 어떤 증상을 보이는가
- 테스트 오차의 기댓값을 0으로 만들 수 없는 이유는 무엇인가

How Can Preprocessing Distort Evaluation?

Next Lecture: Data Leakage

- 특성을 다듬는 전처리
- 결측값과 범주형 변수의 처리
- 데이터 누수와 파이프라인