



부산대학교

PUSAN NATIONAL UNIVERSITY

Logistic Regression

Predicting a Probability

Odds, Sigmoid, and Decision Boundary

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Logistic Regression

Probabilities, Not Values

선형 점수·확률·범주 결정을 서로 다른 단계로 설명한다

같은 선형 점수라도 출력은 달라진다


분류(classification)에서 로지스틱 회귀(logistic regression)는 점수를 확률로 바꿔 범주를 정한다

구분	선형 회귀	로지스틱 회귀
공통 출발점	선형 점수 $z = \beta_0 + \beta^T x$	선형 점수 $z = \beta_0 + \beta^T x$
출력 변환	z 를 예측값으로 사용	$\sigma(z)$ 를 확률로 사용
마지막 결정	수치 $\hat{y}$ 를 출력	확률에 임계값을 적용

β_0, β 를 θ_0, θ 로 쓰기도 한다.

선형 점수, 확률 예측, 범주 결정의 역할을 분리해 읽는다


잔액·소득과 연체 여부



가로축은 잔액, 세로축은 소득이며 주황이 연체한 사람이다

Source: James et al. (2023), Figure 4.1a.


연체 여부에 따른 잔액과 소득 분포



연체 여부에 따라 잔액 분포는 크게 다르지만 소득 분포는 많이 겹친다

Source: James et al. (2023), Figure 4.1b.

선형 회귀 예측값은 확률 범위를 벗어날 수 있다



왼쪽 직선은 0 아래로 내려가고, 오른쪽 곡선은 항상 0과 1 사이에 머문다

Source: James et al. (2023), Figure 4.2.

선형 회귀를 확률에 적용할 때의 문제

문제	내용
범위를 벗어난다	확률이 0보다 작거나 1보다 커진다
확률로 해석할 수 없다	음수인 예측값은 발생 확률이 될 수 없다
조건부 분산이 일정하지 않다	이진 결과의 분산 $p(1 - p)$ 가 확률에 따라 변한다
범주가 셋 이상이다	0, 1, 2로 부호화하면 없던 순서와 간격이 생긴다

선형식의 값을 확률로 쓰려면 (0, 1) 범위로 변환해야 한다

Source: James et al. (2023), Section 4.2.

분류 문제는 범주를 예측한다

분류할 범주의 수는 문제에 따라 다르다

예	범주 수	묻는 것
연체 여부	둘	이 사람이 연체할까
메일 분류	둘	이 메일이 스팸인가
손글씨 숫자	열	이 그림이 어느 숫자인가

아래에서 다루는 로지스틱 회귀는 범주가 둘인 경우다

예측 확률을 출력하는 이유

모델 출력	활용
예측 범주	어느 범주로 분류했는지 알 수 있다
예측 확률	각 범주의 추정 확률을 알 수 있다
예측 확률	분류 기준을 바꾸어 결정을 내릴 수 있다

예측 확률과 최종 범주 결정은 구분한다

조건부 확률로 범주 1을 예측한다

모델은 $X = x$ 가 주어졌을 때 $Y = 1$ 일 확률을 추정한다

$$p(x) = \Pr(Y = 1 \mid X = x)$$

개념	이 문제에서의 뜻
확률변수 Y	연체 여부를 0 또는 1로 나타낸다
확률	$X = x$ 일 때 $Y = 1$ 일 확률

sigmoid 함수로 값을 (0, 1) 범위로 변환한다

sigmoid 함수는 S자 모양의 곡선으로, 실수를 (0, 1) 범위의 값으로 바꾼다

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

z	$\sigma(z)$	뜻
크게 음수	0에 가깝다	범주 1의 확률이 낮다
0	0.5	두 범주의 확률이 같다
크게 양수	1에 가깝다	범주 1의 확률이 높다

Source: James et al. (2023), Section 4.3.1.

sigmoid 함수로 확률을 계산한다

선형 점수에 sigmoid 함수를 적용해 확률을 계산한다

$$p(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

구분	기호	이 모델에서
입력	z	$\beta_0 + \beta_1 x$
출력	$\sigma(z)$	확률 $p(x)$
매개변수	β_0, β_1	선형 점수를 결정

Source: James et al. (2023), Equation 4.2.

Checkpoint

Probabilities, Not Values

- 회귀와 분류는 예측하는 대상이 어떻게 다른가
- 직선을 그대로 확률에 쓰면 무엇이 어긋나는가
- sigmoid 함수는 무엇을 무엇으로 바꾸는가

Section 2 • Logistic Regression

Linear Score and Log Odds

확률·승산·로그 승산의 관계를 설명한다

확률을 승산으로 나타낸다

승산(odds)은 어떤 사건이 일어날 확률과 일어나지 않을 확률의 비다

$$\text{odds} = \frac{p}{1 - p}$$

p	승산	해석
0.5	1	발생 대 비발생이 1 : 1
0.8	4	발생 대 비발생이 4 : 1
0.1	1/9	발생 대 비발생이 1 : 9

Source: James et al. (2023), Section 4.3.1.

로그 승산을 선형식으로 나타낸다

로지스틱 회귀는 로그 승산(log odds)이 입력의 선형식이라고 가정한다

$$\log \frac{p(X)}{1 - p(X)} = \beta_0 + \beta_1 X$$

표현	범위	로지스틱 회귀에서
확률 p	$(0, 1)$	sigmoid 함수의 출력
승산	$(0, \infty)$	선형 점수의 지수
로그 승산	실수 전체	입력의 선형식

Source: James et al. (2023), Equation 4.4.

로그 승산을 승산과 확률로 바꾼다

로그 승산

$$z = \beta_0 + \beta_1 x$$

승산

$$o = e^z$$

확률

$$p = \frac{o}{1 + o}$$

sigmoid 함수는 로그 승산 z 를 확률 p 로 바꾼다

계수는 로그 승산의 변화를 나타낸다

X 가 1 증가할 때 β_1 은 확률이 아니라 로그 승산의 변화량이다

대상	X 가 1 증가할 때의 변화
로그 승산	β_1 만큼 더해진다
승산	e^{β_1} 배가 된다
확률	출발점에 따라 변화량이 다르다

Source: James et al. (2023), Section 4.3.1.

입력을 1씩 늘리며 확률을 계산한다

$\beta_0 = -1.5, \beta_1 = 1$ 일 때 $x = 0, 1, 2$ 의 로그 승산, 승산, 확률을 구한다

x	로그 승산 z	승산 e^z	확률 p
0	-1.5	0.223	0.182
1	-0.5	0.607	0.378
2	0.5	1.649	0.622

z 가 1씩 늘면 승산은 $e \approx 2.72$ 배가 되지만 확률 증가폭은 0.20, 0.24로 다르다

두 회귀 모델의 계수 추정 기준

두 회귀 모델은 서로 다른 기준으로 계수를 추정한다

구분	선형 회귀	로지스틱 회귀
추정 기준	잔차 제곱합(RSS)	정답 범주의 우도(likelihood)
계수 선택	RSS 최소화	우도 최대화
계산 방법	식 하나로 바로 계산	식으로 바로 풀 수 없어 반복 최적화 사용


sigmoid 함수의 구간별 기울기

점수가 같은 폭으로 늘어도 확률 증가폭이 구간마다 다른 이유

구간	기울기	확률 변화
양 끝	완만하다	같은 점수 변화에 확률이 조금 변함
가운데	가파르다	같은 점수 변화에 확률이 더 크게 변함

관측된 결과의 우도를 최대화한다

관측들이 독립이라는 가정 아래, 각 관측의 정답 범주에 준 확률을 곱한다



Source: James et al. (2023), Section 4.3.2.

정답 범주에 낮은 확률을 줄수록 손실이 커진다

정답 범주에 준 확률의 음의 로그를 손실로 쓴다

$$\ell(y, p) = -y \log p - (1 - y) \log(1 - p)$$

정답	예측 확률	손실
$y = 1$	$p = 0.9$	$-\log 0.9 \approx 0.11$
$y = 1$	$p = 0.1$	$-\log 0.1 \approx 2.30$
$y = 0$	$p = 0.9$	$-\log(1 - 0.9) \approx 2.30$
$y = 0$	$p = 0.1$	$-\log(1 - 0.1) \approx 0.11$

$\log$ 는 자연로그다

Source: James et al. (2023), Section 4.3.2.

음의 로그 우도는 손실의 합이다

$\beta_0 = -1.5, \beta_1 = 1$ 의 세 확률과 관측값 $y = 0, 1, 1$ 로 우도와 손실을 계산한다

x	p	y	정답 범주의 확률	손실
0	0.182	0	0.818	0.201
1	0.378	1	0.378	0.974
2	0.622	1	0.622	0.474

$$\text{우도} = 0.818 \times 0.378 \times 0.622 \approx 0.192, \quad -\log(\text{우도}) = 0.201 + 0.974 + 0.474 \approx 1.65$$

손실 합이 $-\log(\text{우도})$ 이므로 우도가 가장 큰 계수에서 손실 합이 가장 작다

추정한 계수로 연체 확률을 계산한다

Default 자료에서 잔액만 쓴 모델의 추정값은 $\hat{\beta}_0 = -10.6513$, $\hat{\beta}_1 = 0.0055$ 다

잔액 x (달러)	로그 승산 $\hat{\beta}_0 + \hat{\beta}_1 x$	연체 확률 $\hat{p}(x)$
1,000	-5.15	0.00576
2,000	0.35	0.586

잔액이 1,000달러 늘면 로그 승산은 5.5 늘고 승산은 $e^{5.5} \approx 245$ 배가 된다

설명변수가 여럿일 때

설명변수(predictor)마다 계수를 두고 선형 점수에 더한다

$$\log \frac{p(X)}{1 - p(X)} = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

$p(X)$ 는 확률이고, 첨자 p 는 설명변수의 수다

여러 설명변수의 가중합으로 로그 승산을 나타낸다

Checkpoint

Linear Score and Log Odds

- 승산과 확률은 무엇이 다른가
- 로지스틱 회귀는 로그 승산과 입력 사이에 어떤 관계를 가정하는가
- 다른 입력을 고정하고 X_1 이 1 증가하면 승산은 몇 배가 되는가

Probability to Decision

임계값으로 예측 범주를 정하고 결정 경계를 해석한다

확률에 임계값을 적용해 범주를 정한다

임계값(threshold)을 기준으로 확률을 예측 범주로 바꾼다

예측 확률	임계값 0.5	임계값 0.2
0.622	범주 1	범주 1
0.378	범주 0	범주 1
0.182	범주 0	범주 0

모델의 예측 확률이 같아도 임계값에 따라 예측 범주는 달라진다

예측 범주가 바뀌는 경계

DEFINITION

결정 경계(decision boundary)

예측 범주가 바뀌는 경계. 로지스틱 회귀에서 임계값이 0.5이면 로그 승산이 0인 곳이다

설명변수	선형 결정 경계
하나	축 위의 한 점
둘	평면 위의 직선

앞 예($\beta_0 = -1.5$, $\beta_1 = 1$)의 경계는 임계값 0.5에서 $x = 1.5$, 임계값 0.2에서 $x \approx 0.11$ 이다

오류 비용에 따라 임계값을 정한다

연체를 놓치는 오류와 연체로 잘못 분류하는 오류의 비용은 다를 수 있다

틀리는 방식	예	임계값을 낮추면
연체를 놓친다	실제 연체를 비연체로 예측	줄거나 유지된다
연체로 오인한다	실제 비연체를 연체로 예측	늘거나 유지된다

임계값은 오류의 비용과 목적을 고려해 검증 자료에서 선택한다


불균형 자료에서는 정확도만으로 평가할 수 없다

상황	정확도만 사용한 결과
연체가 100명 중 3명이다	모두 비연체로 예측해도 97%가 맞는다
연체를 탐지하지 못한다	실제 연체한 3명을 모두 놓친다

정확도(맞힌 비율) 하나로는 불균형 자료의 모델을 판단할 수 없다



로지스틱 회귀의 예측 과정

선형 점수를 로그 승산, 확률, 예측 범주로 차례로 바꾼다



용어	뜻
로지스틱 회귀	로그 승산을 입력의 선형식으로 나타내는 모델
승산	$p/(1 - p)$
로그 승산	승산에 로그를 취한 값
sigmoid 함수	실수를 (0, 1)로 바꾸는 함수
임계값	확률로부터 예측 범주를 정하는 기준
결정 경계	예측 범주가 바뀌는 경계

잔액을 통제하면 학생 여부와 연체의 관계가 달라진다



주황은 학생, 파란은 학생이 아닌 사람이다. 왼쪽 실선은 잔액별 연체율, 점선은 전체 연체율이다. 학생은 잔액이 큰 경우가 많아 전체 연체율은 높지만, 같은 잔액에서는 연체율이 더 낮다

Source: James et al. (2023), Figure 4.3.

전처리와 모델을 함께 학습한다

요소	역할	적용
척도 조정	계수를 찾는 반복 계산을 안정시킴	모델 학습 전
범주 부호화(encoding)	범주를 수치 입력으로 변환	모델 학습 전
파이프라인	실행 순서 고정	전처리와 모델을 묶음

선형 경계는 복잡한 관계를 놓칠 수 있다

실제 경계가 복잡할 때 선형 경계로 제한하면 과소적합할 수 있다

성질	로지스틱 회귀	유연한 분류기
경계	직선 또는 초평면	휘어질 수 있다
편향	커질 수 있다	줄어들 수 있다
분산	작은 경향이 있다	커질 수 있다

관계를 더 유연하게 표현하면 학습 자료의 변화에도 민감해질 수 있다

선형 경계로 분리할 수 없는 자료

선형 경계로는 나눌 수 없는 자료가 있다

자료의 모양	선형 경계의 결과
두 무리가 한 줄로 나뉜다	분리할 수 있다
한 무리가 다른 무리를 감싼다	분리할 수 없다
두 무리가 겹친다	어떤 경계로도 완전히 나눌 수 없어 확률로 불확실성을 나타낸다

한 무리가 다른 무리를 감싸면 특성을 변환하거나 다른 모델을 쓴다

Checkpoint

Probability to Decision

- 임계값을 낮추면 어느 종류의 오류가 늘어날 수 있는가
- 로지스틱 회귀의 결정 경계는 어떤 모양인가
- 정확도가 높아도 실제 연체를 모두 놓칠 수 있는 이유는 무엇인가

How Does a Model Find Its Parameters on Its Own?

Next Lecture: Gradient Descent

- 목적함수와 손실의 관계
- 그래디언트 반대 방향으로 갱신하는 절차
- 학습률이 하는 일