



부산대학교

PUSAN NATIONAL UNIVERSITY

Backpropagation

Working Backwards

The Chain Rule Through a Network

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Backpropagation

Gradient-Based Training

경사하강법의 갱신 규칙을 신경망 전체에 적용한다

신경망의 매개변수도 그래디언트로 갱신한다

역전파(backpropagation)는 손실을 각 매개변수로 미분한 그래디언트(gradient)를 구한다

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L$$

θ 는 신경망의 모든 가중치와 절편을 모은 매개변수 벡터다

은닉층의 가중치는 여러 연산을 거쳐 손실에 영향을 준다

대상	계산 관계
출력층의 가중치	출력과 손실 계산을 거쳐 영향을 준다
은닉층의 가중치	은닉층·출력층·손실 계산을 거쳐 영향을 준다
각 단계의 미분	연쇄법칙(chain rule)으로 연결한다

은닉층의 가중치는 거치는 연산이 더 많아 연쇄법칙으로 곱하는 미분도 더 많다


매개변수 수가 늘면 수치 미분의 비용도 커진다

784 → 256 → 128 → 1 구조에는 매개변수가 233,985개 있다

방법	모든 미분값을 구하는 계산	전체 비용
중앙차분 수치 미분	매개변수마다 순전파 두 번	$O(PC)$
역전파	순전파 한 번과 역전파 한 번	$O(C)$

P 는 매개변수 수, C 는 순전파 비용이며 손실 하나를 미분하는 경우다. 중앙차분은 매개변수 하나를 $\pm \epsilon$ 만큼 바꾼 두 손실의 차이로 미분값을 근사한다

미니배치마다 예측·미분·갱신을 반복한다



역전파는 그래디언트를 계산하고, 갱신 규칙은 그 값으로 매개변수를 바꾼다

Checkpoint

Gradient-Based Training

- 신경망을 학습시킬 때 갱신 규칙은 무엇인가?
- 은닉층의 가중치는 어떤 연산들을 거쳐 손실에 영향을 주는가?
- 한 번의 갱신을 이루는 네 단계는 무엇인가?

Section 2 • Backpropagation

The Computational Graph

순전파의 계산 과정을 그래프로 나타낸다

계산 그래프는 연산의 의존 관계를 나타낸다


DEFINITION

계산 그래프(computational graph)

값과 연산을 노드로, 계산의 의존 관계를 화살표로 나타낸 그림

계산 방향	전달하는 정보
순전파(forward pass)	입력에서 출력으로 각 연산의 값을 계산
역전파	출력에서 입력 방향으로 미분값을 전달

손계산할 2-2-1 신경망의 계산 그래프



각 상자는 값과 계산을 묶어 표시한다. $z, h \in \mathbb{R}^2$ 이고, x 에서 L 까지는 h_1 과 h_2 를 거치는 두 경로가 있으며 W_1 의 각 행은 그중 한 경로에만 놓인다. 손계산을 위해 제곱 손실을 쓰며(L 은 관측 하나의 손실 $\mathcal{L}$ 과 같은 대상), 분류에서는 보통 로지스틱 손실을 쓴다

계산의 의존 관계가 미분 경로를 정한다

은닉층의 가중치가 바뀌면 중간값을 거쳐 손실이 바뀐다

대상	계산 관계
W_1 에서 L 까지	z, h, s 를 차례로 거친다
각 경로의 미분	경로에 있는 연산들의 미분을 곱한다
여러 경로의 영향	각 경로에서 구한 미분값을 더한다

순전파의 중간값을 저장해 역전파에 사용한다

대상	계산 관계
순전파에서 h 사용	$s = w_2^\top h + b_2$ 계산
역전파에서 h 사용	$\partial L / \partial w_2$ 계산
중간값 저장	h 를 다시 계산하지 않고 재사용

순전파의 중간값과 역전파의 미분값을 재사용해 중복 계산을 줄인다

여러 경로로 전달된 영향은 더한다

같은 값 u 가 두 연산에 쓰이면 두 경로의 미분값을 합한다

$$L = a(u) + b(u) \quad \Longrightarrow \quad \frac{dL}{du} = \frac{da}{du} + \frac{db}{du}$$

은닉 유닛 하나가 다음 층의 여러 유닛에 연결되면, 그 연결들에서 돌아온 미분값을 합한다. 뒤의 2-2-1 예에서는 입력 x_1 이 두 은닉 유닛에 쓰여 $\partial L / \partial x_1 = (-1.5)(1) + (6)(1) = 4.5$ 다

Checkpoint

The Computational Graph

- 계산 그래프에서 값·연산·화살표는 각각 무엇을 나타내는가?
- 순전파와 역전파는 그래프 위에서 어느 방향으로 진행되는가?
- 순전파의 중간값을 저장해 두는 이유는 무엇인가?

Section 3 • Backpropagation

Chain Rule on One Neuron

유닛 하나에서 연쇄법칙을 직접 적용한다

가중치에서 손실까지 세 단계로 계산한다

가중치가 손실에 미치는 영향을 가중합·활성함수·손실로 나누어 계산한다

단계	식	무엇에서 무엇으로
1	$z = w^T x + b$	가중치에서 z 로
2	$a = g(z)$	z 에서 출력으로
3	$L(a, y)$	출력에서 손실로

$$\frac{\partial L}{\partial w_j} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w_j}$$

w_j 는 가중치 벡터의 한 성분이다. 마지막 미분값은 $\partial z / \partial w_j = x_j$ 다

연쇄법칙의 세 미분값

조각	값	계산 예
$\partial L / \partial a$	손실이 정한다	$L = \frac{1}{2}(a - y)^2$ 이면 $a - y$
$\partial a / \partial z$	$g'(z)$	ReLU는 $z \neq 0$ 에서 0 또는 1
$\partial z / \partial w_j$	x_j	해당 입력 성분

저장한 입력과 중간값을 이용해 각 연산의 미분값을 계산한다

ReLU의 미분

z	$g(z)$	$g'(z)$
$z > 0$	z	1
$z < 0$	0	0
$z = 0$	0	정의되지 않음

Caution $z < 0$ 이면 이 활성화함수를 통해 입력 쪽으로 전달되는 미분값은 0이다

절편의 미분에는 입력을 곱하지 않는다

$$\frac{\partial z}{\partial b} = 1 \quad \implies \quad \frac{\partial L}{\partial b} = \frac{\partial L}{\partial a} \cdot g'(z)$$

가중치의 미분에서 x_j 를 곱하던 자리에 1이 들어간다

하나의 미분값을 여러 매개변수에 재사용한다

출력 쪽에서 구한 δ 를 각 가중치와 절편의 미분에 공통으로 사용한다

$$\delta = \frac{\partial L}{\partial a} g'(z)$$

$$\frac{\partial L}{\partial w_j} = \delta x_j, \quad \frac{\partial L}{\partial b} = \delta$$

각 w_j 를 미분할 때마다 손실에서 z 까지의 미분을 새로 계산할 필요가 없다

Checkpoint

Chain Rule on One Neuron

- $\partial L / \partial w_j$ 를 세 조각으로 어떻게 나누는가?
- 각 조각의 값은 어디에서 오는가?
- $z < 0$ 인 ReLU 유닛에서 그래디언트는 어떻게 되는가?

Backward Through a Hidden Layer

2-2-1 신경망의 모든 매개변수에 대한 미분값을 구한다

순전파 결과와 손실에서 출발한다

$h_1 = \text{ReLU}(x_1 + x_2)$, $h_2 = \text{ReLU}(x_1 + x_2 - 1)$, $s = h_1 - 4h_2 - 0.5$ 에 $x = (1, 1)$ 을 넣는다

z_1, z_2	h_1, h_2	s	y
2, 1	2, 1	-2.5	-1

즉 W_1 의 두 행은 모두 $(1, 1)$, $b_1 = (0, -1)^\top$, $w_2 = (w_{2,1}, w_{2,2})^\top = (1, -4)^\top$, $b_2 = -0.5$
손실은 $L = \frac{1}{2}(s - y)^2 = \frac{1}{2}(-1.5)^2 = 1.125$ 다. 부호는 맞지만 s 가 $y = -1$ 에서 벗어나 있으므로 제곱 손실은 0이 아니다

출력층의 그래디언트를 먼저 계산한다

구하는 것	식	값
$\partial L / \partial s$	$s - y$	-1.5
$\partial L / \partial w_{2,1}$	$(s - y) h_1$	-3.0
$\partial L / \partial w_{2,2}$	$(s - y) h_2$	-1.5
$\partial L / \partial b_2$	$s - y$	-1.5

출력 가중치의 미분값은 $(s - y)$ 에 해당 은닉 유닛의 출력값을 곱해 구한다

출력의 미분값을 은닉층으로 전달한다

손실을 h_1, h_2 로 미분하여 은닉층으로 전달한다

구하는 것	식	값
$\partial L / \partial h_1$	$(s - y) w_{2,1}$	-1.5
$\partial L / \partial h_2$	$(s - y) w_{2,2}$	+6.0

같은 미분값 -1.5에 출력 가중치 1, -4를 곱하므로 크기와 부호가 달라진다

활성함수를 미분해 가중합으로 전달한다

유닛	$\partial L / \partial h$	$g'(z)$	$\partial L / \partial z$
유닛 1	-1.5	1	-1.5
유닛 2	+6.0	1	+6.0

$z_1 = 2, z_2 = 1$ 로 둘 다 양수이므로 ReLU의 미분값은 1이다

은닉층의 가중치와 절편까지 미분한다

$x = (1, 1)^\top$, $\delta_z = \partial L / \partial z = (-1.5, 6)^\top$ 를 사용한다

$$\frac{\partial L}{\partial W_1} = \delta_z x^\top = \begin{bmatrix} -1.5 & -1.5 \\ 6 & 6 \end{bmatrix} \quad \frac{\partial L}{\partial b_1} = \delta_z = \begin{bmatrix} -1.5 \\ 6 \end{bmatrix}$$

W_1 의 각 행은 은닉 유닛 하나의 가중치이며, b_1 에는 두 유닛의 절편이 들어 있다

한 번의 역전파로 모든 매개변수를 미분한다

항목	값
순전파 횟수	한 번
역전파 횟수	한 번
얻은 미분값	가중치 6개와 절편 3개, 총 9개

한 번의 역전파가 모든 매개변수의 그래디언트를 함께 계산하며, 비용은 순전파와 같은 차수다

중앙차분으로 미분값을 대조한다

나머지 매개변수는 고정하고 $w = w_{2,1}$ 만 바꾼다

$$\frac{\partial L}{\partial w} \approx \frac{L(w + \varepsilon) - L(w - \varepsilon)}{2\varepsilon}, \quad \varepsilon = 10^{-6}$$

방법	$\partial L / \partial w_{2,1}$
연쇄법칙	-3.000000
중앙차분	약 -3.000000

Caution 차이가 크면 구현 오류뿐 아니라 차분 간격과 미분 불가능한 지점도 확인한다

구한 미분값으로 출력 가중치를 갱신한다

다른 매개변수는 그대로 두고 두 출력 가중치만 한 번 갱신한다

매개변수	그래디언트	$\eta = 0.1$ 이면
$w_{2,1}$	-3.0	$1 \rightarrow 1.3$
$w_{2,2}$	-1.5	$-4 \rightarrow -3.85$

그래디언트가 음수라 두 가중치가 커지고 s 는 -2.5 에서 -1.75 로 $y = -1$ 에 가까워진다

미니배치의 평균 손실을 미분한다

$$L_B(\theta) = \frac{1}{B} \sum_{i=1}^B L_i(\theta)$$

$$\nabla_{\theta} L_B(\theta) = \frac{1}{B} \sum_{i=1}^B \nabla_{\theta} L_i(\theta)$$

B 는 미니배치 크기다. 같은 매개변수 θ 에서 구한 관측별 그래디언트를 평균한다

Checkpoint

Backward Through a Hidden Layer

- $\partial L / \partial s$ 의 값은 얼마이고 어떻게 나왔는가?
- $\partial L / \partial h_1 = -1.5$, $\partial L / \partial h_2 = 6$ 이 되는 이유는 무엇인가?
- 그래디언트를 맞게 구했는지 어떻게 확인하는가?

Section 5 • Backpropagation

When to Stop Training

학습을 언제 멈출지 곡선으로 판단한다


학습 손실과 검증 손실을 함께 추적한다

매개변수 갱신에서 제외한 검증 자료에서도 손실이 줄어드는지 확인한다

손실 곡선	손실 계산 자료	나타날 수 있는 경향
학습	가중치 갱신에 쓴 자료	학습이 진행되며 감소
검증	갱신에서 제외한 자료	감소하다 다시 증가

학습 손실은 줄고 검증 손실은 계속 커지면 과적합을 의심한다

목적함수와 분류 오류는 다르다



왼쪽은 목적함수 값, 오른쪽은 분류 오류율이다. 검증 목적함수는 6에포크 무렵 가장 작고 30에포크에는 약 0.11로 오르지만, 검증 오류율은 그 뒤에도 약 0.024에서 0.02 안팎으로 조금 더 줄어든다

Source: James et al. (2023), Figure 10.18.

손실 감소가 성능 향상을 보장하지 않는다

변화	해석할 때의 주의점
학습 손실 감소	새 자료의 손실은 오히려 커질 수 있다
같은 구조로 학습 반복	층 수를 늘리지 않아도 과적합이 나타날 수 있다

검증 자료로 학습 종료 시점을 정한다

단계	하는 일	판단 기준
1	검증 자료를 따로 둔다	가중치 갱신에는 사용하지 않는다
2	기준 하나를 정해 기록한다	에포크마다 검증 손실 또는 검증 오류율
3	개선이 없으면 멈춘다	정한 에포크 수 동안 나아지지 않을 때
4	사용할 가중치를 고른다	기준값이 가장 좋았던 에포크의 가중치

scikit-learn `MLPClassifier(early_stopping=True)`는 검증 정확도를 기준으로 삼고, 멈춘 뒤 가장 좋았던 가중치로 되돌린다

검증 손실과 검증 오류율은 가장 좋은 시점이 다를 수 있으므로 기준을 먼저 정한다

검증과 테스트의 역할

자료	사용 시점과 역할
검증	학습을 멈출 시점 등 모델을 선택하는 데 사용
테스트	모델 선택을 마친 뒤 최종 성능을 평가

모델의 예측·미분·갱신은 서로 다른 계산이다

개념	역할
경사하강법	그래디언트의 반대 방향으로 매개변수 갱신
미니배치 SGD	일부 자료로 전체 평균 그래디언트 추정
선형 분류기	선형 점수와 결정 경계로 범주 예측
다층 신경망	비선형 활성화함수를 결합해 예측
역전파	연쇄법칙으로 각 매개변수의 미분값 계산

역전파가 계산한 그래디언트를 경사하강법 또는 SGD의 갱신 규칙에 사용한다

Checkpoint

When to Stop Training

- 학습 손실이 줄어도 검증 손실이 커질 수 있는 이유는 무엇인가?
- 두 곡선 사이에 차이가 있다는 사실만으로 과적합을 단정할 수 있는가?
- 학습을 멈출 시점을 정할 때 검증과 테스트 중 어느 자료를 사용하는가?

Can You Explain Every Step of Learning?

Next Lecture: Cross-Validation

- 한 번의 분할로 얻은 점수를 믿기 어려운 이유
- 학습·검증·테스트 자료의 역할
- 자료를 여러 부분으로 나누어 평가하는 교차검증