부산대학교
PUSAN NATIONAL UNIVERSITY

Evaluation Metrics

Choosing What to Measure

Squared Error, Confusion Matrices, and ROC Curves

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Evaluation Metrics

Regression Metrics

예측 오차를 평가지표로 요약한다

예측 오차를 지표로 요약한다

오차 계산

관측마다 $y_i - \hat{y}_i$ 계산

→

지표 계산

평가지표(evaluation metric)로 요약

→

모델 비교

같은 평가 자료와 지표 사용

회귀 지표가 요약하는 값

지표	계산	단위	해석
MSE	오차 제곱의 평균	관측값 단위의 제곱	큰 오차에 큰 벌점
RMSE	MSE의 제곱근	관측값과 같음	오차 크기를 원래 단위로
MAE	절대 오차의 평균	관측값과 같음	오차 크기에 비례한 벌점
R^2	결정계수, 평균 예측 대비 오차 감소	없음	같은 자료의 기준선과 비교

Source: scikit-learn MOOC (2022), regression metrics.

절대 오차의 합이 같아도 MSE는 다르다

10개 관측의 절대 오차	MSE	MAE
10, 나머지 9개는 0	100/10 = 10	10/10 = 1
10개 모두 1	10/10 = 1	10/10 = 1

MSE는 오차가 일부 관측에 집중된 경우 더 커진다

평가 목적에 맞는 회귀 지표

평가 목적	지표	주의할 점
큰 오차를 강하게 반영	MSE, RMSE	제곱 때문에 큰 오차의 영향이 큼
오차를 선형적으로 반영	MAE	이상치의 영향이 없어지는 것은 아님
평균 예측과 비교	R^2	관측값 분포가 다르면 단순 비교 금지
원래 단위로 오차 보고	RMSE, MAE	두 지표의 계산 방식은 다름

> 무엇을 큰 오류로 볼지에 따라 지표를 먼저 정한다

R^2의 기준선은 평가 자료의 평균

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$$

값	평가 자료에서의 의미
1	예측 오차가 0
0	평가 자료의 평균을 항상 예측한 것과 같은 제곱오차
음수	그 평균을 항상 예측한 것보다 제곱오차가 큼

관측값이 모두 같아 분모가 0인 경우는 이 식으로 정의되지 않는다

같은 예측 결과를 네 지표로 계산한다

가상 관측값 $y = (2, 4, 6, 8)$, 예측값 $\hat{y} = (2, 5, 5, 10)$

MSE	RMSE	MAE	R^2
$6/4 = 1.50$	$\sqrt{1.5} \approx 1.22$	$4/4 = 1.00$	$1 - 6/20 = 0.70$

절대 오차는 0, 1, 1, 2다. RMSE는 항상 MAE 이상이고 모든 절대 오차가 같을 때만 같으므로, RMSE가 더 크다는 사실만으로 이상치를 단정할 수 없다

Checkpoint

Regression Metrics

- MSE와 MAE는 큰 예측 오차를 어떻게 다르게 반영하는가
- RMSE를 보고에 쓰는 까닭은 무엇인가
- R^2가 음수이면 무슨 뜻인가

Section 2 • Evaluation Metrics

The Confusion Matrix

분류 결과를 네 칸으로 나눈다

이진분류의 두 가지 오류

DEFINITION

거짓 양성(FP)

실제 음성인 관측을 양성으로 예측한 경우

DEFINITION

거짓 음성(FN)

실제 양성인 관측을 음성으로 예측한 경우

FP는 false positive, FN은 false negative를 뜻한다

혼동행렬로 분류 결과를 나타낸다



혼동행렬의 관측 수로 정확도·정밀도·재현율을 계산한다

Source: James et al. (2023), Section 4.4.

양성 클래스를 정한다

문제	양성 클래스	까닭
질환 검사	환자	환자를 찾아내기 위해
불량품 검사	불량	불량품을 놓치지 않기 위해
스팸 분류	스팸	스팸을 걸러 내기 위해

Caution 양성 클래스에 따라 정밀도와 재현율의 해석이 달라지지만 정확도는 변하지 않는다

정확도는 전체 중 맞힌 비율이다

$$\text{정확도} = \frac{TP + TN}{TP + FP + FN + TN}$$

반영하는 것	반영하지 않는 구분
전체 중 맞힌 비율	FP와 FN의 상대적인 비용

전체 관측 수가 0보다 클 때 정의된다

혼동행렬을 읽을 때는 축을 먼저 확인한다

이 표의 방향	합의 의미	계산할 수 있는 비율
양성 예측 행	$TP + FP$: 양성 예측 수	정밀도 $= TP/(TP + FP)$
실제 양성 열	$TP + FN$: 실제 양성 수	재현율 $= TP/(TP + FN)$
대각선	$TP + TN$: 맞힌 수	정확도의 분자

도구마다 행·열 방향이 다르므로 축 이름을 먼저 확인한다. scikit-learn의 `confusion_matrix`는 행이 실제, 열이 예측이며 라벨 오름차순이라 0/1이면 음성(0)이 먼저다

Default 자료의 실제 혼동행렬

로지스틱 회귀(잔액·소득·학생 여부)를 고객 7,000명으로 학습하고 평가 자료 3,000명에 임계값 0.5 적용

예측 / 실제	연체(양성)	연체 아님(음성)
연체	$TP = 39$	$FP = 9$
연체 아님	$FN = 74$	$TN = 2{,}878$

앞의 네 칸 표와 같은 방향(행 예측, 열 실제, 양성 먼저)이다. 정확도는 $(39 + 2{,}878)/3{,}000 \approx 0.972$지만 실제 연체 113명 중 39명만 찾았다

Data: James et al. (2023), Default.

Checkpoint

The Confusion Matrix

- 두 종류의 실수는 각각 무엇인가
- 양성 클래스를 먼저 정해야 하는 이유는 무엇인가
- 정확도는 네 칸 중 어느 칸을 세는가

Section 3 • Evaluation Metrics

Precision and Recall

혼동행렬에서 정밀도와 재현율을 계산한다

정밀도와 재현율의 분모

DEFINITION

정밀도(precision)

양성으로 예측한 관측 중 실제 양성의 비율

$$\frac{TP}{TP + FP}$$

DEFINITION

재현율(recall)

실제 양성 중 양성으로 예측한 비율

$$\frac{TP}{TP + FN}$$

각 분모가 0보다 클 때 정의되며, 분모가 0이면 별도의 처리 규칙이 필요하다

Source: UBC CPSC 330 (2026), classification metrics.

혼동행렬에서 직접 계산한다

가상 관측 1,000개 중 실제 양성은 20개, 양성 예측은 15개

예측 / 실제	양성	음성
양성	$TP = 12$	$FP = 3$
음성	$FN = 8$	$TN = 977$

정밀도 $12/15 = 0.80$, 재현율 $12/20 = 0.60$

민감도와 특이도

지표	계산	조건 집단
재현율 = 민감도(sensitivity) = TPR(true positive rate)	$TP/(TP+FN)$	실제 양성
특이도(specificity) = TNR(true negative rate)	$TN/(TN+FP)$	실제 음성
FPR(false positive rate) = $1-$ 특이도	$FP/(FP+TN)$	실제 음성

> 이름이 달라도 분자와 분모가 같으면 같은 지표다

정밀도와 재현율의 조화평균

$$F_1 = \frac{2PR}{P + R} \qquad (P + R > 0)$$

정밀도 P	재현율 R	F_1
0.80	0.60	$24/35 \approx 0.69$
0.80	0.80	0.80

F_1은 두 값이 불균형하면 산술평균보다 작지만, 한쪽만 개선해도 높아질 수 있다

하나의 지표만으로 판단하지 않는다

가상 관측 1,000개, 양성 20개	정밀도	재현율	F_1
모두 양성으로 예측	0.02	1.00	0.04
실제 양성 1개만 양성으로 예측	1.00	0.05	0.10
앞의 혼동행렬	0.80	0.60	0.69

Caution 한쪽 지표가 1이어도 다른 오류와 그 비용을 함께 확인해야 한다

scikit-learn으로 같은 지표를 계산한다

앞의 Default 표를 만든 코드다. `X`는 잔액·소득·학생 여부(학생=1), `y`는 연체=1이다. 분할·파이프라인·모델의 import 줄은 생략했다

```
from sklearn.metrics import (confusion_matrix, precision_score,
                             recall_score, f1_score)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=0)
model = make_pipeline(StandardScaler(), LogisticRegression())
y_pred = model.fit(X_train, y_train).predict(X_test)
print(confusion_matrix(y_test, y_pred))
# [[2878    9]
#  [  74   39]]
for score in (precision_score, recall_score, f1_score):
    print(score.__name__, round(score(y_test, y_pred), 4))
# precision_score 0.8125
# recall_score 0.3451
# f1_score 0.4845
```

출력 행렬은 행이 실제, 열이 예측이고 라벨 오름차순(0, 1)이라 앞의 표를 전치하고 양성·음성 순서를 바꾼 모양이다. 세 함수는 `pos_label=1`을 양성으로 둔다. 손으로 계산하면 $39/48$, $39/113$, $78/161$이다

Adapted from scikit-learn MOOC (2022), classification metrics · data: James et al. (2023), Default.

Checkpoint

Precision and Recall

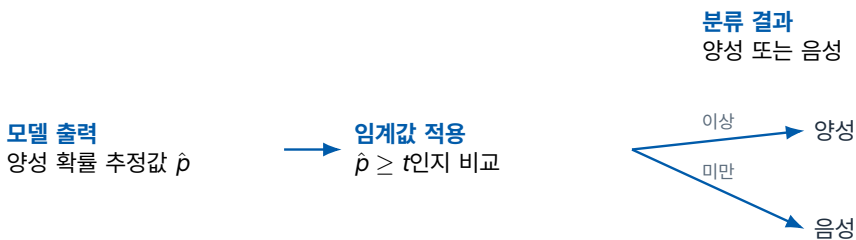
- 두 비율의 분모는 각각 무엇인가
- 재현율과 민감도는 어떤 관계인가
- F_1이 산술평균이 아닌 까닭은 무엇인가

Section 4 • Evaluation Metrics

Threshold and ROC

한 모델에서 여러 분류기를 만든다

확률 추정값을 분류 결과로 바꾼다



같은 모델도 임계값에 따라 혼동행렬이 달라질 수 있다

임계값을 낮추면 양성 예측이 늘어난다

앞의 가상 자료에서 실제 양성 20개, 음성 980개는 그대로 유지

임계값	*TP*	*FP*	*FN*
0.8	6	1	14
0.5	12	3	8
0.2	18	25	2

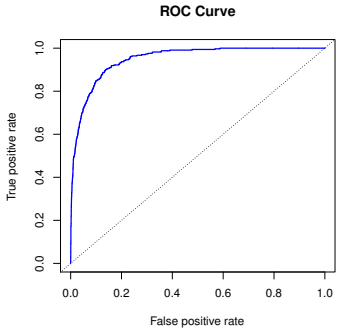
고정된 예측값에서 임계값을 낮추면 FP는 늘거나 같고 FN은 줄거나 같다

ROC 곡선의 두 축

축	지표	계산
세로축	TPR, 재현율	$TP/(TP+FN)$
가로축	FPR	$FP/(FP+TN)$

실제 양성과 음성이 모두 있는 자료에서 임계값마다 두 비율을 계산해 점을 잇는다. 앞 표의 세 임계값은 (FPR, TPR) = (0.001, 0.30), (0.003, 0.60), (0.026, 0.90)이다

ROC 곡선



Default 자료에서 연체 여부를 예측한 분류기의 ROC 곡선(AUC 0.95). 왼쪽 위는 TPR이 높고 FPR이 낮은 영역이며 대각선은 무작위 순위의 기준선이다

Source: James et al. (2023), Figure 4.8.

ROC 곡선 아래 면적(AUC)은 점수의 순위를 평가한다

AUC	평가 자료에서의 해석
1.0	모든 양성의 점수가 모든 음성의 점수보다 높음
0.5	양성·음성 쌍의 평균 순위 성능이 무작위 수준
0.5 미만	점수 방향과 양성 범주의 지정부터 확인

점수는 양성 확률 추정값 $\hat{p}$다. AUC는 양성의 점수가 음성보다 높을 확률에 동점 확률의 절반을 더한 값과 같다

AUC가 0.5라는 사실만으로 모델이 아무것도 학습하지 않았다고 단정할 수 없다

같은 FPR도 오류 건수는 다르다

실제 음성 수	FPR	*FP*
1,000	1%	10
10,000	1%	100

Caution ROC는 범주별 비율을 보여 주므로 실제 FP 건수는 혼동행렬에서 함께 확인한다

지표와 함께 보고할 정보

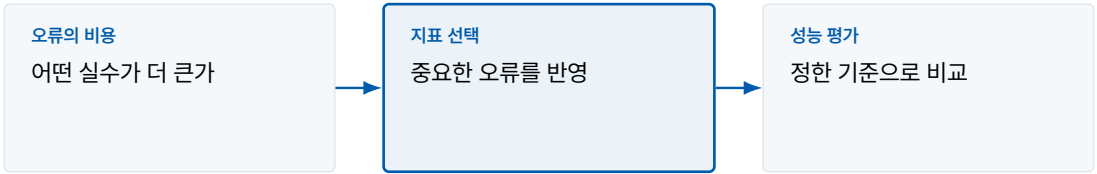
함께 적는 것	왜
혼동행렬 그대로	네 칸의 실제 수를 보인다
사용한 임계값	같은 모델도 임계값에 따라 결과가 달라진다
양성 클래스	정밀도와 재현율의 해석이 정해진다
범주별 비율	정확도를 읽는 기준이 된다

> 지표 값 하나만으로는 어떤 오류가 얼마나 발생했는지 알 수 없다

오늘의 용어

용어	무엇을 가리키는가
혼동행렬	실제 범주와 예측 범주별 관측 수를 나타낸 표
정밀도	양성이라 답한 것 중 실제 양성의 비율
재현율	실제 양성 중 찾아낸 비율
F_1	정밀도와 재현율의 조화평균
ROC 곡선	임계값을 바꾸며 얻은 점 (FPR, TPR)을 이은 곡선

평가지표는 문제의 목적에 맞춰 고른다



결과를 본 뒤 유리한 지표로 바꾸지 않도록 평가 기준을 먼저 정한다

한 혼동행렬에서 여러 지표를 보고한다

가상 자료, 양성 20개, 음성 980개, 임계값 0.5

지표	계산
정확도	$(12 + 977)/1{,}000 = 0.989$
정밀도	$12/(12 + 3) = 0.80$
재현율	$12/(12 + 8) = 0.60$
F_1	$24/(24 + 3 + 8) \approx 0.69$

임계값 하나의 혼동행렬만으로 ROC AUC를 계산할 수는 없다

모델의 평가 기준을 먼저 정한다

먼저 정할 것	어떤 실수가 더 곤란한가
그다음	그에 맞는 지표를 고른다
마지막	결과와 함께 그 근거를 적는다

> 모델을 평가할 지표는 결과를 보기 전에 정한다

Checkpoint

Threshold and ROC

- 임계값을 내리면 FN과 FP는 각각 어떻게 되는가
- 곡선 아래 면적이 0.5면 무슨 뜻인가
- 같은 FPR에서 실제 음성 수가 늘면 FP 건수는 어떻게 되는가

Why Would You Fit the Data Less Well on Purpose?

Next Lecture: Regularization

- 예측 오차를 편향·분산·잡음으로 분해하기
- 계수의 크기에 벌점 매기기
- 벌점의 세기를 검증으로 고르기

오용경 yongkyung.oh@pusan.ac.kr