부산대학교
PUSAN NATIONAL UNIVERSITY

Naive Bayes

Turning the Question

From Class Densities to Class Odds

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Naive Bayes

Bayes Theorem for Classification

조건부 확률의 방향을 바꾸어 범주를 예측한다

같은 검사라도 조건이 달라지면 확률이 다르다

조건	확률이 답하는 질문
질환이 있다는 사실을 안다	$P(+ \mid \text{질환})$: 검사가 양성일 확률
검사가 양성이라는 사실을 안다	$P(\text{질환} \mid +)$: 질환이 있을 확률

베이즈 정리로 사후확률을 계산한다

$$P(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}$$

$\pi_k = P(Y = k)$이며, f_k는 범주 k의 조건부 확률질량함수 또는 밀도함수

Caution 연속형 특성의 밀도 $f_k(x)$는 한 점의 확률 $P(X = x \mid Y = k)$가 아니다

Source: James et al. (2023), Section 4.4.

사전확률·조건부 분포·사후확률을 구분한다

요소	의미	계산에 사용하는 정보
사전확률(prior)	x를 보기 전 범주 확률	모집단을 대표하는 범주 비율
범주별 조건부 분포	해당 범주에서 특성값의 분포	범주별 학습 관측
사후확률(posterior)	x를 관측한 뒤 범주 확률	사전확률과 조건부 분포

양성 확률과 질환의 사후확률을 계산한다

범주	사전확률	양성일 확률	두 확률의 곱
질환 있음	0.01	0.90	0.0090
질환 없음	0.99	0.05	0.0495

가상 검사: $P(+) = 0.0585$, $P(\text{질환} \mid +) = 0.0090/0.0585 \approx 15.4\%$

10,000명을 검사할 때의 기대 인원으로 읽는다

범주	전체 인원	양성 기대 인원
질환 있음	100	$100 \times 0.90 = 90$
질환 없음	9,900	$9{,}900 \times 0.05 = 495$
합계	10,000	585

양성 585명 중 질환이 있는 기대 인원은 90명이므로 $90/585 \approx 15.4\%$다

범주별 값을 계산한 뒤 합으로 나눈다

사전확률 반영

π_k를 준비

→

조건부 분포 반영

$s_k = \pi_k f_k(x)$ 계산

→

사후확률 계산

$s_k / \sum_l s_l$

분모가 양수일 때 모든 범주의 사후확률 합은 1

민감도가 높아도 양성일 때 질환의 사후확률은 별도로 계산한다

확인할 값	앞 예제의 값	의미
민감도	0.90	질환이 있는 사람 중 양성 비율
거짓 양성률(FPR)	0.05	질환이 없는 사람 중 양성 비율
질환의 사전확률	0.01	검사 전 모집단의 질환 비율

Caution 질환이 드물면 양성 중 상당수가 질환이 없는 사람에게서 나올 수 있다

사후확률이 가장 큰 범주를 선택한다

$$\hat{y} = \arg\max_k P(Y = k \mid X = x) = \arg\max_k \pi_k f_k(x)$$

이 규칙을 베이즈 분류기(Bayes classifier)라 한다. 모든 오분류의 비용이 같은 경우이며, 분모는 범주 간 비교에서 공통이다

자료에서 추정한 사전확률과 조건부 분포를 대입해 예측 규칙을 만든다

두 범주의 사후확률비를 비교한다

$$\frac{P(Y=1 \mid x)}{P(Y=0 \mid x)} = \underbrace{\frac{\pi_1}{\pi_0}}_{\text{사전확률비}} \times \underbrace{\frac{f_1(x)}{f_0(x)}}_{\text{조건부 분포의 비}}$$

분모가 양수인 경우의 식이며, 앞 검사 예제에서는 $(0.01/0.99)(0.90/0.05) = 2/11$

> 같은 오분류 비용에서 비가 1보다 크면 범주 1, 작으면 범주 0을 선택한다

Checkpoint

Bayes Theorem for Classification

- 사전확률과 범주별 조건부 분포는 각각 무엇을 말하는가
- 검사 예제에서 민감도만으로 사후확률을 알 수 없는 이유는 무엇인가
- 범주를 선택할 때 분모를 생략해도 되는 까닭은 무엇인가

Section 2 • Naive Bayes

Estimating from Data

사전확률과 범주별 조건부 분포를 추정한다

추정은 분포 식의 빈자리를 자료로 채운다

베이즈 분류기에 넣을 사전확률과 범주별 조건부 분포를 자료로 추정한다

추정할 값	자료에서 구할 값	예측에서의 역할
사전확률 π_k	범주 k의 관측 비율	범주의 기본 빈도
평균 μ_{kj}	범주별 특성 평균	밀도 곡선의 중심
분산 σ_{kj}^2	범주별 특성 분산(관측 수로 나눔)	밀도 곡선의 퍼짐

j는 특성 번호이며, 평균·분산은 정규분포를 가정할 때 추정한다

가정한 분포에서 이 비율·평균·분산은 최대우도 추정(maximum likelihood estimation, MLE)의 해와 같다

대표성 있는 학습 자료에서 사전확률을 추정한다

범주	관측 수	$\hat{\pi}_k$
범주 1	60	0.20
범주 0	240	0.80

$\hat{\pi}_k = n_k / n$이며, n_k는 범주 k의 관측 수, n은 전체 학습 관측 수

Caution 범주 균형을 맞추려고 표본 수를 조정한 뒤의 비율을 모집단의 사전확률로 그대로 쓰지 않는다

가우시안 모델은 범주별 정규분포를 추정한다

분포 가정
연속형 특성에 정규분포 사용

→

매개변수 추정
범주별 평균·분산 계산

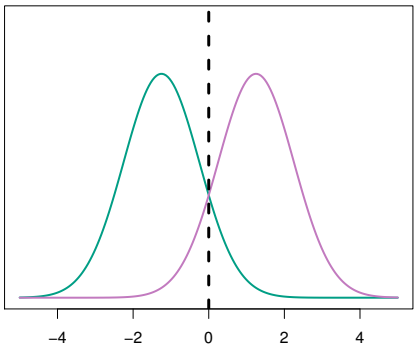
→

밀도 계산
새 특성값을 밀도함수에 대입

$$f_k(x) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x-\mu_k)^2}{2\sigma_k^2}\right)$$

범주 k의 정규분포(가우스 분포, Gaussian distribution) 밀도. 이 분포는 한 가지 모델 가정이며, 적합성은 학습·검증 자료에서 확인한다

사전확률이 같으면 밀도 곡선의 교점이 결정 경계다



동일한 사전확률

- 평균이 $-1.25, 1.25$이고 분산이 1인 두 정규분포
- $\pi_0 = \pi_1$이므로 밀도가 같은 $x = 0$이 결정 경계
- 파선 왼쪽과 오른쪽에서 큰 밀도의 범주 선택

Source: James et al. (2023), Figure 4.4, left panel.

가중한 밀도를 비교해 예측한다

비교 결과	같은 오분류 비용에서의 예측
$\pi_1 f_1(x) > \pi_0 f_0(x)$	범주 1
$\pi_1 f_1(x) < \pi_0 f_0(x)$	범주 0
$\pi_1 f_1(x) = \pi_0 f_0(x)$	사전에 정한 동률 처리 규칙 적용

밀도 곡선이 여러 번 교차하면 결정 경계도 여러 개일 수 있다

사전확률이 달라지면 분류 기준도 달라진다

$$\pi_1 f_1(x) > \pi_0 f_0(x) \quad \Longleftrightarrow \quad \frac{f_1(x)}{f_0(x)} > \frac{\pi_0}{\pi_1}$$

$\pi_0, \pi_1, f_0(x) > 0$이고 두 조건부 분포를 고정한 경우

범주 1이 더 드물수록 범주 1을 선택하는 데 필요한 밀도비가 커진다

조건부 분포의 가정은 자료와 대조한다

학습 자료의 형태	가정이 어긋날 수 있는 이유
한쪽으로 긴 꼬리	대칭인 정규분포로는 꼬리 밀도를 설명하기 어렵다
뚜렷한 두 봉우리	단일 정규분포로 두 집단을 표현하기 어렵다
범주형 특성	연속 밀도 대신 각 특성값의 확률을 모델링해야 한다

Caution 가정과 설정은 학습·검증 자료에서 점검하고 테스트 결과에 맞추어 바꾸지 않는다

Checkpoint

Estimating from Data

- 사전확률은 자료에서 어떻게 구하는가
- 범주별 조건부 분포의 평균과 분산은 어느 관측으로 구하는가
- 한 범주가 더 드물면 그 범주를 선택하는 밀도비 기준은 어떻게 변하는가

Section 3 • Naive Bayes

The Naive Assumption

특성이 여럿일 때 결합분포를 단순화한다

이진 특성의 결합분포는 매개변수가 빠르게 늘어난다

특성 수 p	제약 없는 결합분포	조건부 독립 가정
1	1	1
2	3	2
20	1,048,575	20

한 범주 안에서 이진 특성 p개의 확률을 추정할 때 각각 $2^p - 1$개와 p개의 자유 매개변수

범주가 주어졌을 때의 독립을 가정한다

DEFINITION

조건부 독립

범주를 고정했을 때 여러 특성의 결합분포를 각 특성의 조건부 분포의 곱으로 나타낼 수 있는 성질

나이브 베이즈는 모든 범주에서 특성들의 조건부 독립을 가정

Source: James et al. (2023), Section 4.4.4.

조건부 독립 가정으로 결합분포를 곱으로 바꾼다

$$f_k(x) \;=\; f_{k1}(x_1) \times f_{k2}(x_2) \times \cdots \times f_{kp}(x_p)$$

특성 p개의 결합분포 하나를 추정하는 대신 특성별 분포 p개를 추정한다

Source: James et al. (2023), Section 4.4.4.

가우시안 나이브 베이즈의 매개변수 수를 센다

추정 대상	범주 2개·특성 2개일 때
특성별 평균	$2 \times 2 = 4$개
특성별 분산	$2 \times 2 = 4$개
사전확률	$\pi_0 + \pi_1 = 1$이므로 자유 매개변수 1개

평균 4개, 분산 4개, 사전확률의 자유 매개변수 1개로 총 9개를 추정한다

조건부 독립은 전체 자료에서의 독립과 다르다

살펴보는 자료	독립 가정의 의미
같은 범주에 속한 관측만	특성들의 결합분포를 개별 분포의 곱으로 나타낸다
모든 범주를 합친 관측	범주별 평균이 다르면 특성들이 연관되어 보일 수 있다

전체 자료의 상관계수만으로 조건부 독립 여부를 판단할 수는 없다

특성의 자료형에 맞는 나이브 베이즈 모델을 선택한다

특성의 종류	예시 모델	범주별 추정값
연속형	가우시안 나이브 베이즈	특성별 평균과 분산
범주형	범주형 나이브 베이즈	특성의 각 값이 나타날 확률

연속형에 정규분포를 사용하는 것은 자동으로 성립하는 사실이 아니라 모델 가정

이진 특성 두 개의 조건부 확률을 곱한다

범주	π_k	$P(X_1 = 1 \mid k)$	$P(X_2 = 1 \mid k)$
1	0.20	0.60	0.30
0	0.80	0.10	0.20

$x_1 = x_2 = 1$인 예제의 가중 확률은 각각 $0.036, 0.016$

범주 1의 사후확률은 $0.036/(0.036 + 0.016) \approx 69.2\%$다

특성 세 개의 밀도를 곱해 사후확률을 계산한다

$\hat{\pi}_1 = \hat{\pi}_2 = 0.5$**, 새 관측** $x^* = (0.4,\ 1.5,\ 1)$**. 앞의 두 특성은 수치형, 셋째는 범주형이다**

범주 k	$\hat{f}_{k1}(0.4)$	$\hat{f}_{k2}(1.5)$	$\hat{f}_{k3}(1)$	세 값의 곱
1	0.368	0.484	0.226	0.0403
2	0.030	0.130	0.616	0.0024

$$P(Y = 1 \mid X = x^*) = \frac{0.5 \times 0.0403}{0.5 \times 0.0403 + 0.5 \times 0.0024} \approx 0.944$$

사전확률이 같아 약분된다. 수치형 특성의 $\hat{f}$는 정규분포를 가정하면 앞의 밀도식에 범주별 평균·분산을 넣어 구한다(예: $N(0,\ 1)$에서 0.4의 밀도는 0.368)

Adapted from James et al. (2023), Section 4.4.4.

서로 다른 특성이라고 해서 독립인 것은 아니다

자료의 예	범주를 고정한 뒤 확인할 관계
문서의 단어	같은 주제 안에서도 함께 나타나는 단어가 있는가
여러 장비의 측정값	공통 환경의 영향을 함께 받는가
설문의 서로 다른 문항	비슷한 성향을 반복해서 측정하는가

> 같은 범주 안에서 남는 의존성이 약할수록 조건부 독립 가정에 더 가깝다

Checkpoint

The Naive Assumption

- 특성이 스물이면 결합분포 추정이 왜 어려운가
- 조건부 독립 가정은 무엇을 없다고 두는 것인가
- 연속형과 범주형 특성에는 각각 어떤 분포를 쓰는가

Section 4 • Naive Bayes

When the Assumption Bends

모델의 예측 성능과 확률 추정의 한계를 구분한다

Smarket 자료에 나이브 베이즈를 적용한다

Lag1, Lag2는 각각 1일 전·2일 전 수익률이며, 이 둘로 해당 날짜의 상승·하락을 예측한다

```
import pandas as pd
from sklearn.naive_bayes import GaussianNB
Smarket = pd.read_csv("data/Smarket.csv")
X = Smarket[["Lag1", "Lag2"]]
train = Smarket["Year"] < 2005
model = GaussianNB().fit(X.loc[train],
                         Smarket.loc[train, "Direction"])
y_pred = model.predict(X.loc[~train])
```

Source: James et al. (2023), Ch. 4 lab, Naive Bayes.

2005년 테스트 결과를 혼동행렬로 읽는다

	실제 하락	실제 상승
하락 예측	29	20
상승 예측	82	121

항상 상승으로 예측해도 정확도는 $141/252 \approx 56.0\%$다. 범주 안 두 특성의 상관은 0에 가깝지만(하락 -0.03, 상승 -0.02), 상관이 0이라고 조건부 독립이 성립하지는 않는다

정확도는 $150/252 \approx 59.5\%$이며, 테스트 자료는 모델 선택에 다시 사용하지 않는다

Source: James et al. (2023), Ch. 4 lab, Smarket Naive Bayes result.

서로 닮은 특성은 증거를 중복시킨다

한 일	일어나는 일	점검할 내용
거의 같은 특성을 둘 넣음	같은 증거를 두 번 센다	검증 성능과 확률 추정의 품질을 확인
강한 상관이 남음	독립 가정과 어긋난다	다른 모델과 비교

특성을 무조건 지우기보다 같은 분할에서 예측과 확률 품질을 비교한다

나이브 베이즈를 검토할 만한 상황

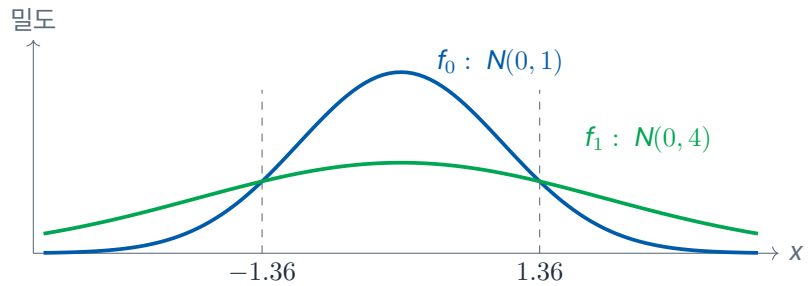
상황	판단	까닭
특성이 아주 많다	후보가 된다	추정할 것이 비교적 적다
학습 자료가 적다	비교할 가치가 있다	강한 가정이 분산을 줄일 수 있다
빠른 기준모델이 필요하다	적합하다	학습과 예측이 단순하다
신뢰할 수 있는 확률이 필요하다	검증이 필요하다	독립 가정이 확률을 치우치게 할 수 있다

가우시안 나이브 베이즈와 로지스틱 회귀를 비교한다

관점	가우시안 나이브 베이즈	이진 로지스틱 회귀
모델링 대상	범주별 특성 분포와 사전확률	특성이 주어졌을 때의 범주 확률
매개변수	비율, 특성별 평균과 분산	절편과 회귀계수
특성 분포	범주 안에서 조건부 독립 가정	특성 분포는 모델링하지 않는다
확률 계산	가중 밀도를 합으로 나눔	선형 예측값에 sigmoid 적용

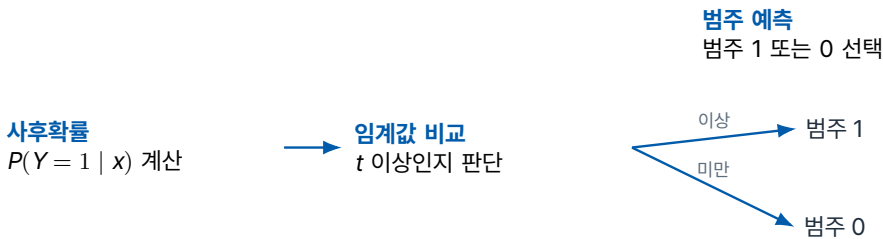
Source: James et al. (2023), Sections 4.4.4, 4.5.

분산이 다르면 결정 경계가 두 곳일 수 있다



$N(\mu, \sigma^2)$는 평균 μ, 분산 σ^2인 정규분포다. $\pi_0 = \pi_1$이면 두 밀도가 같은 $x^2 = 8 \ln 2/3$이 경계라 $|x| < 1.36$이면 범주 0, 바깥이면 범주 1이다. 특성이 x 하나인 로지스틱 회귀는 경계를 한 곳만 만든다

이진 분류는 임계값으로 확률을 예측에 연결한다



두 범주의 최대 사후확률 규칙은 같은 오분류 비용에서 $t = 0.5$에 해당

분류 성능과 확률 추정의 품질을 구분한다

사용 목적	확인할 내용
범주 선택	혼동행렬과 목적에 맞는 분류 지표
임계값 변경	검증 자료에서 정밀도·재현율의 변화
확률 자체의 해석	예측 확률과 실제 발생 비율이 얼마나 일치하는지

Caution 강한 의존성을 무시하면 확률이 과도하게 극단적일 수 있으므로 별도로 점검한다

Checkpoint

When the Assumption Bends

- 서로 닮은 특성을 함께 넣으면 무엇이 잘못될 수 있는가
- Smarket 예제의 정확도 59.5%는 항상 상승으로 예측한 경우와 비교해 무엇을 말하는가
- 확률 값 자체를 쓰려 할 때 조심할 것은 무엇인가

What Makes One Estimate Better Than Another?

Next Lecture: Maximum Likelihood

- 확률과 우도의 차이
- 로그 우도를 크게 만드는 값 찾기
- 최대우도 추정과 기존 모델의 연결

오용경 yongkyung.oh@pusan.ac.kr