부산대학교
PUSAN NATIONAL UNIVERSITY

Maximum Likelihood

Parameter Estimation

Log-Likelihood, Gaussian Errors, and Class Models

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Maximum Likelihood

Likelihood as a Function

자료를 고정하고 매개변수를 움직여 본다

동전을 열 번 던졌다

앞면이 일곱 번 나왔을 때 이 동전의 앞면 확률은 얼마라고 할 것인가

던짐	1	2	3	4	5	6	7	8	9	10
결과	앞	뒤	앞	앞	뒤	앞	앞	뒤	앞	앞

앞면은 $y_i = 1$, 뒷면은 $y_i = 0$이며, 각 던짐은 독립이고 앞면 확률은 모두 θ

관측한 결과를 고정하고 우도를 계산한다

$$L(\theta) = P(y_1, \ldots, y_{10} \mid \theta) = \theta^7(1-\theta)^3$$

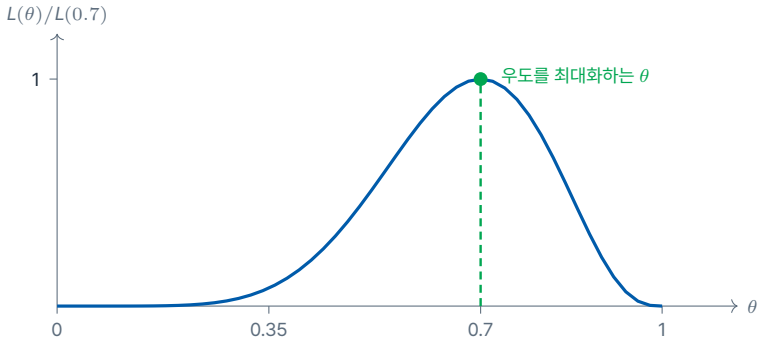
앞서 관측한 특정 순서의 결과에 대해 θ를 바꾸어 비교하는 우도(likelihood)

Caution 우도는 매개변수 θ 자체의 확률이 아니다. 여기서 L은 크게 만들 우도이며, 줄이던 손실 L과 다르다

확률분포와 우도는 변수가 다르다

구분	자료의 확률분포	우도
고정하는 대상	매개변수 θ	관측한 자료
변하는 대상	가능한 자료값	매개변수 θ
비교할 내용	각 결과의 확률 또는 밀도	관측 자료에 대한 상대적 적합도
전체 합(적분)	자료값에 대해 합 또는 적분이 1	매개변수에 대해 합·적분이 1일 필요 없음

θ에 따른 상대우도를 비교한다



앞면 7번·뒷면 3번의 우도를 최댓값으로 나누어 그린 곡선

우도를 최대화하는 추정값

DEFINITION

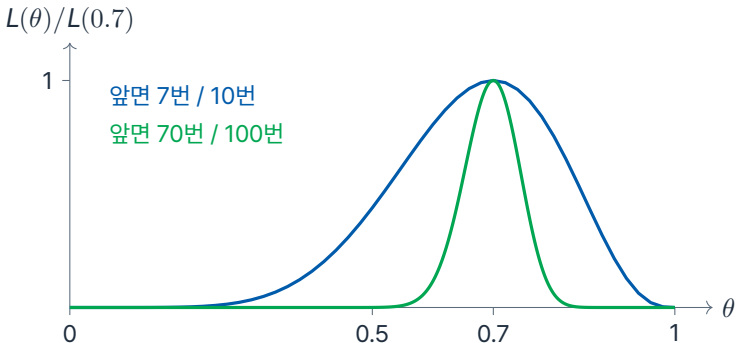
최대우도 추정(MLE)

관측한 자료의 우도를 가장 크게 만드는 매개변수를 추정값으로 선택하는 방법

$$\hat{\theta} = \arg\max_{\theta} L(\theta)$$

동전 예에서 이 값은 앞면의 상대도수 $7/10$과 같다

앞면 비율이 같아도 관측 수에 따라 상대우도가 달라진다



앞면 비율을 0.7로 고정한 비교: 관측 수가 늘면 최대점에서 벗어난 값의 상대우도가 낮아진다

Checkpoint

Likelihood as a Function

- 확률과 우도는 무엇을 고정하고 무엇을 변수로 두는가
- 우도를 매개변수에 대해 더한 값이 반드시 1이어야 하는가
- MLE는 곡선의 어느 자리를 고르는가

Section 2 • Maximum Likelihood

Maximizing the Log-Likelihood

로그 우도를 최대화하는 매개변수를 구한다

독립인 베르누이 관측의 확률을 곱한다

$$L(\theta) = \prod_{i=1}^{n} \theta^{y_i}(1-\theta)^{1-y_i} = \theta^{s}(1-\theta)^{n-s}, \qquad s = \sum_{i} y_i$$

독립이고 동일한 앞면 확률을 가진 관측이며 $0 \leq \theta \leq 1$

Caution 작은 확률을 반복해서 곱하면 값이 너무 작아져 컴퓨터에서 0으로 계산될 수 있다

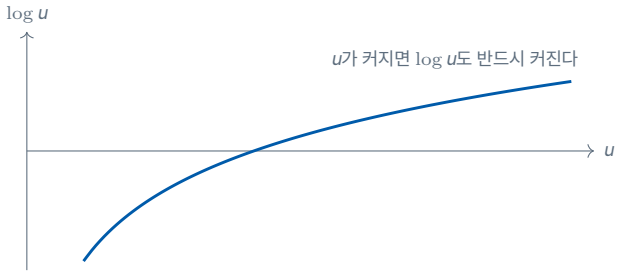
로그 우도는 각 관측의 로그 확률을 더한 값이다

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^{n} [y_i \ln \theta + (1 - y_i) \ln(1 - \theta)] = s \ln \theta + (n - s) \ln(1 - \theta)$$

$0 < \theta < 1$에서 계산하며, 여기서 로그는 자연로그. $\ell(\theta)$는 최대화할 로그 우도이며, 로지스틱 회귀에서 한 관측의 손실로 쓴 $\ell(y, p)$와는 부호가 반대다

> 작은 확률들을 먼저 곱하지 않고 각 항의 로그를 직접 계산해 합산한다

자연로그는 양수에서 증가함수다



$u > 0$에서 자연로그가 순서를 보존하므로 우도와 로그 우도를 최대화하는 매개변수가 같다

0으로 계산되는 시점은 수치 표현 방식에 달려 있다

항의 수 n	Python의 0.5^n	로그의 합 $n \ln 0.5$
10	9.765625×10^{-4}	약 -6.931
1,000	약 9.333×10^{-302}	약 -693.147
1,100	0.0	약 -762.462

일반적인 Python `float`의 이진 64비트 표현에서 계산한 예

0.5^{1000}은 아직 0이 아니지만, 0.5^{1100}은 너무 작아 0으로 반올림된다

미분값을 0으로 두면 $\hat{\theta} = s/n$을 얻는다

앞면 수를 $s = \sum_i y_i$라 두고 $0 < s < n$인 경우를 계산한다

$$\frac{d\ell}{d\theta} = \frac{s}{\theta} - \frac{n-s}{1-\theta} = 0$$

$$s(1-\theta) = (n-s)\theta$$

$$s = n\theta \quad \Longrightarrow \quad \hat{\theta} = \frac{s}{n}$$

$\ell''(\theta) = -s/\theta^2 - (n-s)/(1-\theta)^2 < 0$이므로 구간 내부의 유일한 최대점

모두 앞면이거나 모두 뒷면이면 MLE는 경계값이다

관측한 결과	MLE
앞면 7번, 뒷면 3번	$\hat{\theta} = 7/10 = 0.7$
앞면 10번	$L(\theta) = \theta^{10}$이므로 $\hat{\theta} = 1$
뒷면 10번	$L(\theta) = (1-\theta)^{10}$이므로 $\hat{\theta} = 0$

Caution 모든 결과가 같으면 구간 내부의 미분값이 아니라 경계 $\theta = 0, 1$을 확인한다

정규분포의 평균과 분산을 최대우도로 추정한다

$x_1, \ldots, x_n$이 서로 독립이고 같은 정규분포를 따르며 관측값이 모두 같지는 않다고 가정한다

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_i (x_i - \mu)^2$$

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2}\sum_i (x_i - \mu) = 0 \quad \Rightarrow \ \hat{\mu} = \frac{1}{n}\sum_i x_i$$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_i (x_i - \mu)^2 = 0 \quad \Rightarrow \ \hat{\sigma}^2 = \frac{1}{n}\sum_i (x_i - \hat{\mu})^2$$

Caution 분산의 MLE는 분모가 n이며, 분모가 $n-1$인 표본분산(평균적으로 참값에 맞춘 값)과 다르다

해석적 해가 없으면 수치 최적화를 사용한다

해를 구하는 방법	계산 후 확인할 내용
미분값이 0인 후보를 식으로 계산	후보가 최대점인지, 경계에 더 큰 값이 있는지 확인
수치 최적화로 근사	목적함수의 방향과 제약조건, 수렴 여부를 확인

> 최대우도 추정에서 우도의 최댓값이 항상 존재하거나 수치 최적화가 항상 성공하는 것은 아니다

로그 우도 최대화는 NLL 최소화와 같다

음의 로그 우도(negative log-likelihood, NLL)는 $-\ell(\theta)$이다

$$\max_{\theta} \ \ell(\theta) \qquad \Longleftrightarrow \qquad \min_{\theta} \ \left[-\ell(\theta)\right]$$

$$\theta_{t+1} = \theta_t - \eta \nabla[-\ell(\theta_t)] = \theta_t + \eta \nabla \ell(\theta_t)$$

$\eta > 0$일 때 두 식은 같은 갱신이며, 너무 큰 학습률은 목적함수 개선을 보장하지 않는다

Source: MIT 6.390 (2026), Gradient Descent for Logistic Regression.

우도 곡선을 재현하는 코드

로그 우도에서 최댓값을 뺀 뒤 지수화하면 수치적으로 안정된 상대우도를 얻는다

```
import numpy as np

theta = np.linspace(0.001, 0.999, 500)
loglik = 7*np.log(theta) + 3*np.log1p(-theta)
relative_likelihood = np.exp(loglik - loglik.max())
theta_hat = theta[np.argmax(loglik)]
```

정확한 MLE는 $7/10 = 0.7$이며 격자 코드는 이에 가까운 값을 돌려준다

Checkpoint

Maximizing the Log-Likelihood

- 곱을 합으로 바꾸는 데 로그를 쓰는 까닭 두 가지는 무엇인가
- 로그를 취해도 최대점이 같은 이유는 무엇인가
- NLL 최소화와 로그 우도 최대화의 목적함수는 어떻게 연결되는가

Section 3 • Maximum Likelihood

Behind What We Already Fit

이미 배운 모델의 추정을 한 원리로 연결한다

로지스틱 회귀의 계수

$$\ell(\beta_0, \beta_1) = \sum_{i:\, y_i = 1} \log p(x_i) \; + \sum_{i:\, y_i = 0} \log\bigl(1 - p(x_i)\bigr)$$

$p(x) = 1/(1 + e^{-(\beta_0 + \beta_1 x)})$이고 특성이 주어지면 각 이진 반응은 독립이며, $-\ell$은 관측마다의 로지스틱 손실 $-y_i \log p_i - (1 - y_i) \log(1 - p_i)$를 더한 값이다

정규화 벌점이 없는 로지스틱 회귀는 이 조건부 로그 우도를 최대화한다

Source: James et al. (2023), Section 4.3.2.

정규 오차를 가정하면 최소제곱이 최대우도 추정이다

오차가 서로 독립이고 같은 분산의 정규분포이면 계수의 MLE는 최소제곱과 같다

$$y_i = x_i^{\mathsf{T}}\beta + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

$$-\ell(\beta) = \frac{1}{2\sigma^2}\sum_i (y_i - x_i^{\mathsf{T}}\beta)^2 + C$$

$\sigma^2 > 0$이 고정되면 C는 β와 무관하며, x_i의 첫 성분을 1로 두면 절편도 β에 포함된다

가우시안 나이브 베이즈의 기본 추정값도 MLE다

추정 대상	범주별 최대우도 추정
사전확률	$\hat{\pi}_k = n_k / n$
특성 j의 평균	$\hat{\mu}_{kj} = \sum_{i:y_i=k} x_{ij} / n_k$
특성 j의 분산	$\hat{\sigma}^2_{kj} = \sum_{i:y_i=k} (x_{ij} - \hat{\mu}_{kj})^2 / n_k$

$n_k > 0$이며 범주별 특성 분산이 양수인 기본형. 실제 GaussianNB 구현은 분산에 수치 안정화 항을 추가

세 모델의 추정을 우도 최대화로 다시 읽는다

모델	앞에서 사용한 계산	최대우도 관점
선형 회귀	RSS가 가장 작은 계수를 선택	정규 오차의 우도를 최대화
로지스틱 회귀	정답 범주에 높은 확률을 부여	베르누이 반응의 우도를 최대화
가우시안 나이브 베이즈	범주 비율·평균·분산을 계산	사전확률과 범주별 특성 분포를 최대우도로 추정

정규화 벌점이 없는 기본형이며, 각 행의 대응은 그 행의 분포를 가정할 때 성립한다

최대우도 추정값 하나로 모든 불확실성을 알 수는 없다

MLE가 제공하는 것	추가로 확인할 것
우도를 최대화하는 매개변수	추정값 주변에서 우도가 얼마나 빠르게 줄어드는가
주어진 모델의 자료 적합도	모델의 분포 가정이 자료와 맞는가
학습 자료에 대한 추정값	새 자료에서 예측 성능이 유지되는가

같은 최대점을 가진 곡선이라도 상대우도의 모양은 다를 수 있다

가정이 자료와 맞지 않을 때 생기는 문제

세운 가정	맞지 않으면
오차가 정규분포다	꼬리가 두꺼우면 큰 오차가 제곱합을 좌우할 수 있다
범주 안에서 특성이 독립이다	상관된 특성의 증거가 중복 반영될 수 있다
관측이 독립이다	의존성을 무시하면 추정의 불확실성을 작게 평가할 수 있다

Caution 우도가 높다는 것만으로 분포 가정의 타당성이나 새 자료의 예측 성능이 보장되지는 않는다

계수 크기에 벌점을 더하면 MLE와 목적함수가 달라진다

$$\min_{\beta_0,\beta} \underbrace{-\ell(\beta_0,\beta)}_{\text{음의 로그 우도}} + \underbrace{\lambda\|\beta\|^2}_{\text{특성 계수의 벌점}}, \qquad \lambda \geq 0$$

절편 β_0에는 벌점을 부과하지 않는 경우

$\lambda > 0$이면 우도만 최대화하는 것이 아니라 적합도와 계수 크기를 함께 고려한다

Source: MIT 6.390 (2026), Learning Linear Logistic Classifiers.

Checkpoint

Behind What We Already Fit

- 최소제곱이 어떤 가정에서 따라 나오는가
- 로지스틱 회귀의 계수는 무엇을 가장 크게 하는 값인가
- 가정한 분포가 자료와 맞지 않으면 무엇이 문제가 되는가

Section 4 • Maximum Likelihood

Generative and Discriminative

어떤 확률분포를 모델링할지 구분한다

생성 모델과 판별 모델은 학습 대상이 다르다

DEFINITION

생성 모델

특성과 범주의 결합분포를 모델링하고, 이를 이용해 범주의 사후확률을 계산하는 방식

DEFINITION

판별 모델

특성이 주어졌을 때의 범주 확률이나 범주를 나누는 결정 경계를 직접 학습하는 방식

생성 모델(generative model)과 판별 모델(discriminative model)을 분류 문제에서 비교

생성 모델은 베이즈 정리로 예측 확률을 계산한다

$$P(Y = k \mid x) = \frac{f_k(x)\pi_k}{\sum_l f_l(x)\pi_l}$$

범주별 모델

f_k와 π_k 추정

→

새 관측 대입

$f_k(x)\pi_k$ 계산

→

사후확률

합으로 나누어 계산

f_k는 범주별 조건부 확률질량함수 또는 밀도함수

로지스틱 회귀는 조건부 확률을 직접 추정한다

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

모델 설정

조건부 확률을 식으로 둔다

→

추정

자료로 계수를 추정

→

예측

범주 확률을 바로 계산

가우시안 나이브 베이즈와 로지스틱 회귀의 학습 대상

관점	가우시안 나이브 베이즈	로지스틱 회귀
학습 대상	$f_k(x)\pi_k$	$P(Y = k \mid x)$
특성 분포	범주별로 정규분포를 지정	특성 분포는 학습하지 않는다
모델 가정	범주 안에서 특성의 조건부 독립	로그 승산이 특성의 선형함수
분류	생성 모델의 예	판별 모델의 예

Source: James et al. (2023), Section 4.5.

자료의 양과 가정의 타당성에 따라 유리한 방식이 다르다

상황	확인할 조건	선택 시 고려점
자료가 적다	분포 가정이 타당한가	타당한 가정은 추정을 안정시킬 수 있다
자료가 많다	결정 경계를 충분히 추정하는가	두 방식의 검증 성능을 비교한다
분포 가정이 의심된다	오차가 특정 구간에 몰리는가	범주별 분포를 가정하지 않는 방식도 비교한다

타당한 분포 가정은 추정을 안정시킬 수 있고, 자료와 크게 어긋나면 불리해질 수 있다

두 기본형은 서로 다른 우도를 최대화한다

$$L_{\mathrm{NB}}(\theta) = \prod_i f_{y_i,\theta}(x_i)\pi_{y_i,\theta}$$

$$L_{\mathrm{logistic}}(\theta) = \prod_i P_\theta(Y = y_i \mid X = x_i)$$

관측이 독립이고 정규화 벌점이 없는 나이브 베이즈·로지스틱 회귀 기본형

나이브 베이즈는 결합분포의 우도, 로지스틱 회귀는 조건부 우도를 사용한다

이진 특성의 결합확률에서 사후확률을 계산한다

이진 특성 $x = 1$을 관측한 경우의 계산 예

범주	$P(y)$	$P(x = 1 \mid y)$	$P(x = 1, y)$
$y = 1$	0.4	0.75	0.30
$y = 0$	0.6	0.20	0.12

$$P(y = 1 \mid x = 1) = \frac{0.30}{0.30 + 0.12} \approx 0.714$$

표의 확률이 같은 학습 자료의 관측 비율이고 특성이 이 이진 특성 하나이면 로지스틱 회귀의 최대우도 추정도 같은 0.714를 얻는다. 특성이 여럿이면 두 방법의 값이 달라질 수 있다

2005년 테스트 자료에서 두 모델의 결과를 비교한다

테스트 지표	가우시안 나이브 베이즈	로지스틱 회귀
정확도	$150/252 \approx 0.595$	$141/252 \approx 0.560$
상승 재현율	$121/141 \approx 0.858$	$106/141 \approx 0.752$
상승 정밀도	$121/203 \approx 0.596$	$106/182 \approx 0.582$

2001~2004년 학습, 특성 Lag1·Lag2. 로지스틱 회귀는 정규화 벌점이 없는 기본형이다. 항상 상승으로 예측해도 정확도는 $141/252 \approx 0.560$이다

> 한 번의 테스트 결과로 우열을 일반화할 수 없고, 이 표로 모델을 고르면 테스트 자료가 선택에 쓰인다

Source: James et al. (2023), Ch. 4 lab, Smarket results.

Checkpoint

Generative and Discriminative

- 생성 모델과 판별 모델은 각각 무엇을 학습하는가
- 자료가 적을 때 분포 가정이 도움이 되려면 어떤 조건이 필요한가
- 두 방식에 MLE를 적용하면 최대화하는 우도는 어떻게 다른가

Can You Classify Without Any Probability at All?

Next Lecture: kNN and SVM

- 거리로 가까움을 재는 방법
- 가까운 이웃의 다수결
- 두 범주 사이의 간격을 크게 하는 경계

오용경 yongkyung.oh@pusan.ac.kr