부산대학교
PUSAN NATIONAL UNIVERSITY

Neighbors and Margins

Deciding by Distance

Who Is Nearby, and Where to Draw the Line

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Neighbors and Margins

Distance in Feature Space

두 관측이 얼마나 가까운지를 수로 잰다

수치 특성을 벡터로 표현한다

관측의 특성 수	벡터 표현	공간에서의 위치
2개	$x_i = (x_{i1}, x_{i2})$	평면의 한 점
3개	$x_i = (x_{i1}, x_{i2}, x_{i3})$	3차원 공간의 한 점
p개	$x_i = (x_{i1}, \ldots, x_{ip})$	p차원 공간의 한 점

범주형 특성은 먼저 의미에 맞는 수치 표현으로 변환

두 점 사이의 거리

DEFINITION

유클리드 거리(Euclidean distance)

두 관측이 떨어진 정도를 차이 벡터의 크기 $\|x_i - x_{i'}\|_2$로 측정한 값

$$d(x_i, x_{i'}) = \sqrt{\sum_{j=1}^{p} (x_{ij} - x_{i'j})^2}$$

거리를 직접 계산하기

새 관측 $x_0 = (40,\ 130)$에서 각 관측까지의 거리

번호	나이	검사 수치	차이	거리
1	42	132	$(2,\ 2)$	2.83
2	63	145	$(23,\ 15)$	27.46
3	37	130	$(-3,\ 0)$	3.00
4	41	128	$(1,\ -2)$	2.24

가장 가까운 셋은 4번, 1번, 3번이다. 아직 척도 조정(scaling)을 적용하지 않은 값이다.

특성의 단위와 변동 범위가 거리에 영향을 준다

특성	값의 범위	가능한 최대 차이
나이	20에서 80까지	60
검사 수치	100에서 200까지	100
운동 반응	0 또는 1	1

검사 수치에 10을 곱해 적으면 앞의 최근접 순서가 4·1·3번에서 3·4·1번으로 바뀐다

Caution 척도를 맞추지 않으면 차이가 크게 나타나는 특성이 거리에 더 큰 영향을 줄 수 있다

Checkpoint

Distance in Feature Space

- 두 관측 사이의 유클리드 거리는 어떻게 계산하는가?
- 차이를 제곱해 더하면 부호가 서로 상쇄되지 않는 이유는 무엇인가?
- 특성의 단위를 바꾸면 이웃의 순위가 달라질 수 있는가?

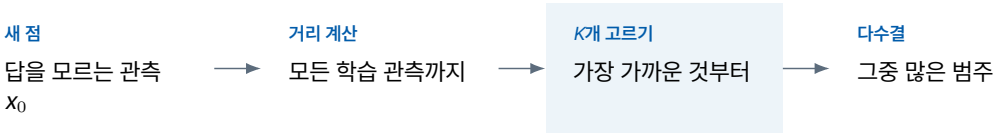
Section 2 • Neighbors and Margins

k-Nearest Neighbors

가까운 이웃의 답을 따른다

가까운 K개의 다수결

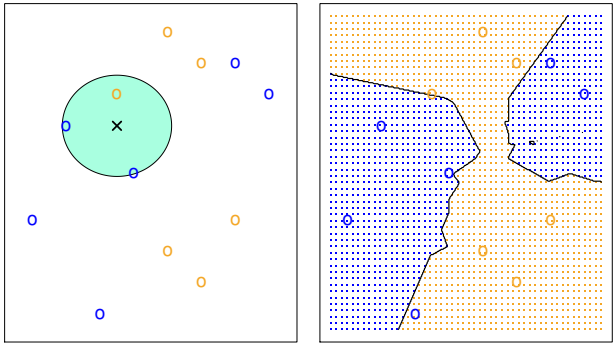
k-최근접 이웃(k-nearest neighbors, kNN)은 가까운 이웃의 정답 범주로 예측한다



가장 가까운 K개의 집합을 neighborhood N_0로 적고, 그 안에서 가장 많은 범주를 선택한다.

Source: James et al. (2023), Section 2.2.3.

$K = 3$일 때



왼쪽은 새 점 둘레의 가장 가까운 셋, 오른쪽은 모든 자리에 같은 규칙을 적용해 얻은 경계

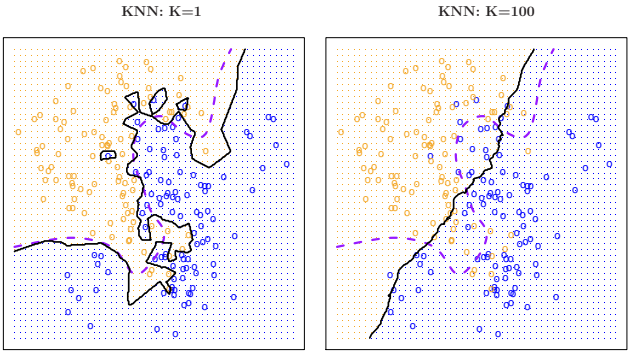
Source: James et al. (2023), Figure 2.14.

kNN의 학습과 예측

단계	수행하는 일
학습	학습 자료와 정답 범주를 저장하고 이웃 검색을 준비한다
예측	새 관측의 가까운 이웃을 찾아 정답 범주를 집계한다

> kNN은 회귀계수를 추정하는 대신 저장한 관측을 예측에 사용한다

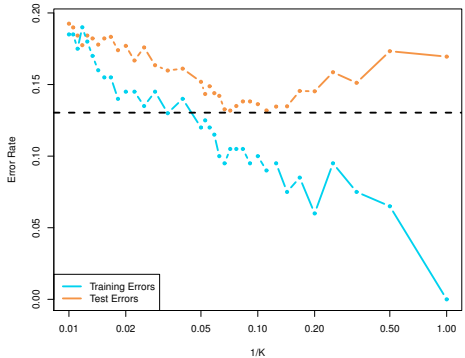
K가 바꾸는 것



$K = 1$은 개별 점에 민감하고 $K = 100$은 경계가 매끈하다.
보라색 파선은 참 분포를 알 때 사후확률이 가장 큰 범주를 고르는 베이즈 경계(Bayes boundary)다.

Source: James et al. (2023), Figure 2.16.

학습 오차와 테스트 오차

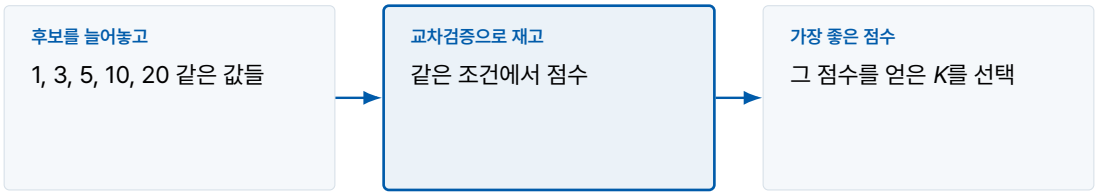


오른쪽으로 갈수록 $1/K$가 커진다. 이 예제의 학습 오차는 줄지만 테스트 오차는 작아지다가 다시 커진다.

Source: James et al. (2023), Figure 2.17.

K를 고르는 법

교차검증 점수로 K 후보를 비교한다



범주 비율이 크게 다르면 정확도 대신 목적에 맞는 지표로 비교한다

Caution 학습 관측 자신을 이웃에 포함하면 $K = 1$의 학습 정확도가 과도하게 높아진다

무관한 특성이 많으면 이웃을 구별하기 어려워진다

특성의 구성	가장 가까운 이웃	결과
관련 특성이 적다	비교적 가까운 이웃을 찾기 쉽다	국소적인 정답 패턴을 활용
무관한 특성이 많다	무관한 차이도 거리에 누적된다	가까운 이웃을 구별하기 어려움

Caution 차원이 늘어날수록 가까운 이웃을 확보하려면 더 많은 관측이 필요할 수 있다

자료가 고르게 퍼져 있지 않을 때

자료의 모양	생기는 일	점검할 내용
한 범주가 훨씬 많다	그 범주가 이웃에서 다수를 차지할 수 있다	지표와 K를 함께 본다
점이 드문 자리	먼 이웃까지 끌어온다	그 구간의 검증 성능을 본다
K번째와 그다음의 거리가 같다	어느 점을 포함할지 모호하다	동률 처리 규칙을 확인한다

홀수 K는 이진 분류에서 다수결 동률을 피하지만, 같은 거리의 이웃을 고르는 문제까지 해결하지는 않는다.

Checkpoint

k-Nearest Neighbors

- K를 작게 하면 경계는 어떻게 달라지는가?
- 학습 정확도만으로 K를 고르면 왜 위험한가?
- 홀수 K가 같은 거리의 이웃 선택 문제도 해결하는가?

Section 3 • Neighbors and Margins

kNN in Code: Choosing K

척도 조정을 포함한 교차검증으로 K를 선택한다

Caravan 자료를 먼저 나눈다

85개 특성으로 보험 가입 여부를 예측한다(import 생략)

```
data = pd.read_csv("data/Caravan.csv")
X = data.drop(columns="Purchase")
y = data.Purchase.eq("Yes").astype(int)
Xtr, Xte, ytr, yte = train_test_split(
    X, y, test_size=1000,
    stratify=y, random_state=13)
```

5,822개 관측 중 4,822개는 학습·교차검증, 1,000개는 최종 평가에 사용한다.

Adapted from James et al. (2023), ISLP Chapter 4 lab, Caravan.

척도 조정도 교차검증 안에서 적합한다

```
cv = StratifiedKFold(3, shuffle=True, random_state=13)
pipe = make_pipeline(StandardScaler(),
                     KNeighborsClassifier())
search = GridSearchCV(
    pipe, {"kneighborsclassifier__n_neighbors": [1, 3, 5]},
    scoring="accuracy", cv=cv)
search.fit(Xtr, ytr)
```

각 분할의 학습 부분에서만 평균과 표준편차를 구한다. 검증 부분에는 그 변환을 적용한다. import 줄은 생략했다.

Source: James et al. (2023), ISLP Chapter 4 lab · scikit-learn Pipeline and GridSearchCV.

같은 분할에서 K 후보 비교하기

척도 조정을 뺀 경우와 넣은 경우를 같은 3개 분할로 비교한다

K	척도 조정 없음	척도 조정 적용
1	88.76%	89.26%
3	92.68%	92.47%
5	**93.59%**	**93.72%**

학습 자료 4,822개의 3개 분할에서 구한 평균 정확도다. 조건마다 가장 높은 값의 K를 골랐다. K가 커질수록 두 조건 모두 항상 No의 94.0%에 가까워진다

Adapted from James et al. (2023), ISLP Chapter 4 lab, Caravan.

선택을 마친 뒤 테스트 자료로 평가한다

방법	K	테스트 정확도	찾아낸 수 / 가입자 수
척도 조정 없음	5	93.3%	0 / 60
척도 조정 적용	5	93.7%	1 / 60
항상 No로 예측	없음	94.0%	0 / 60

따로 둔 1,000개에서 한 번 잰 값이라 앞 쪽의 분할 평균과 다르다. Yes는 보험 가입자이고, 가입자 중 찾아낸 비율인 재현율도 확인한다.

두 모델 모두 항상 No보다 정확도가 낮고 가입자를 거의 찾지 못한다. 가입자가 약 6%인 자료에서 정확도로 K를 고르면 다수 범주 예측에 가까워진다

Adapted from James et al. (2023), ISLP Chapter 4 lab, Caravan.

척도 조정은 이웃을 절반쯤 바꾼다

확인한 값	척도 조정 없음	척도 조정 적용
관측 쌍 제곱거리 합에서 MOSTYPE의 몫	53.6%	1.2%
가까운 5개 이웃 중 MOSTYPE이 같은 비율	71.7%	48.3%
조정 전후에 겹치는 가까운 5개 이웃	49.4%	
$K = 5$ 예측이 달라진 테스트 관측	10 / 1,000	

표의 값은 모두 앞 쪽과 같은 학습·테스트 분할에서 얻었다. MOSTYPE은 1부터 41까지인 고객 유형 번호로 표준편차가 12.8, 나머지 84개 특성의 표준편차 중앙값은 0.86이다

이웃은 절반쯤 바뀌지만 두 모델 모두 거의 항상 No로 예측해 정확도 차이가 작다. 정확도 차이가 작다고 척도 조정의 영향이 작은 것은 아니다

Adapted from James et al. (2023), ISLP Chapter 4 lab, Caravan.

Checkpoint

kNN in Code: Choosing K

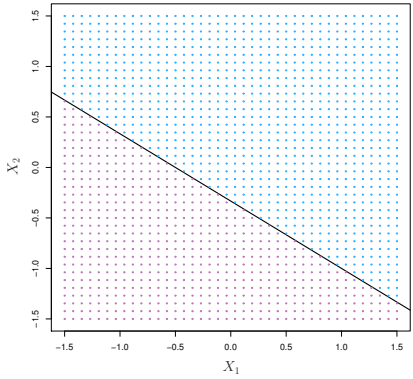
- `n_neighbors`는 어떤 값을 지정하는가?
- 척도 조정을 교차검증 이전에 전체 자료로 적합하면 왜 위험한가?
- 가입자가 적은 자료에서 정확도만으로 결과를 평가하면 무엇을 놓칠 수 있는가?

Section 4 • Neighbors and Margins

Separating Hyperplanes and the Margin

자료를 분리하는 여러 초평면의 마진을 비교한다

초평면의 식과 부호를 연결한다



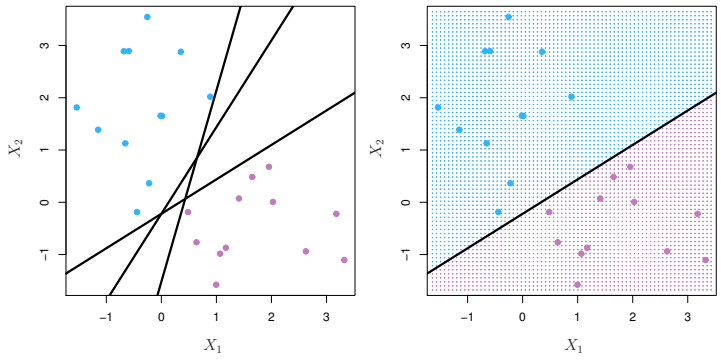
초평면(HYPERPLANE)

$$f(x) = \beta_0 + \beta^T x = 0$$

- $\beta \neq 0$이면 $p-1$차원이며 $p = 2$에서는 직선
- 그림의 식은 $1 + 2x_1 + 3x_2 = 0$
- 파란 쪽은 양수, 보라색 쪽은 음수
- 선형 분리 경계 $w^\top x + b = 0$과 같은 식($\beta_0 = b$, $\beta = w$)

Source: James et al. (2023), Figure 9.1.

두 범주를 완전히 나누는 초평면은 여러 개다



왼쪽은 가능한 분리 초평면 세 개, 오른쪽은 그중 한 경계의 분류 규칙

Source: James et al. (2023), Figure 9.2.

완전히 분리하는 경계 중 마진이 가장 큰 것을 고른다

DEFINITION

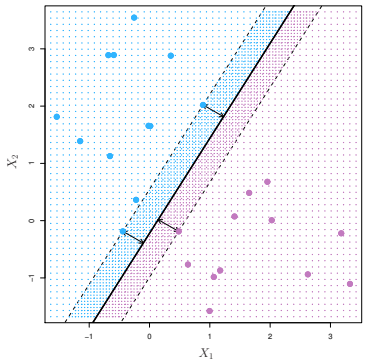
마진(margin)

학습 자료를 완전히 분리하는 초평면에서 가장 가까운 학습 관측까지의 수직거리

$$M = \min_i \frac{|\beta_0 + \beta^\mathsf{T} x_i|}{\|\beta\|_2}$$

$\beta/\|\beta\|_2$는 초평면에 수직인 단위벡터이므로 $f(x)/\|\beta\|_2$가 부호 있는 수직거리다. 경계 양쪽의 빈 띠 전체 폭은 $2M$이다($\beta \neq 0$)

마진과 그 위의 점들



실선이 경계이고 파선까지의 거리가 마진이다. 파선에 닿은 세 점이 경계를 정한다.

Source: James et al. (2023), Figure 9.3.

경계를 결정하는 서포트 벡터

DEFINITION

서포트 벡터(support vector)

완전히 분리 가능한 경우, 마진 위에서 최대 마진 경계의 위치를 결정하는 관측

마진 위반을 허용하면 마진 안쪽의 점도 서포트 벡터가 될 수 있다.

마진 바깥의 다른 점은 그 영역에 머무르는 한 경계를 바꾸지 않는다

고정한 경계에서 작은 입력 변화의 영향을 계산한다

$$d(x, H) = \frac{|f(x)|}{\|\beta\|_2}, \qquad \|\delta\|_2 < d(x, H) \implies f(x+\delta)\text{와 } f(x)\text{의 부호가 같음}$$

H는 고정한 초평면, 위 관계는 $f(x) \neq 0$인 관측에 적용

큰 마진은 학습 관측 주변의 여유를 주지만 테스트 성능을 보장하지는 않는다

Checkpoint

Separating Hyperplanes and the Margin

- 초평면 식의 부호는 무엇을 알려 주는가?
- 분리 가능한 경계가 여럿일 때 마진을 어떻게 비교하는가?
- 다른 관측을 옮겨도 경계가 바뀌지 않으려면 어떤 조건이 필요한가?

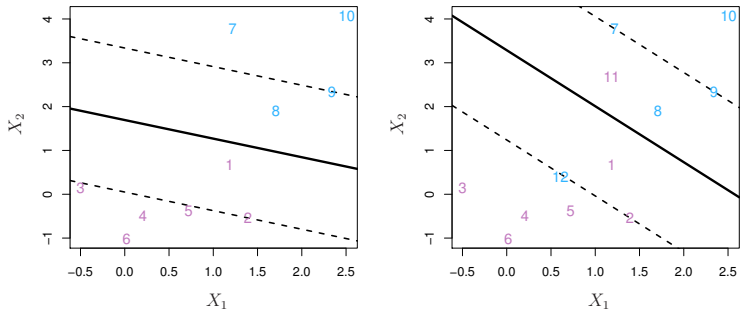
Section 5 • Neighbors and Margins

Support Vector Machines in Practice

나뉘지 않는 자료에서도 경계를 긋는다

완전히 나뉘지 않으면

서포트 벡터 머신(support vector machine, SVM)은 마진을 기준으로 경계를 학습한다



마진 안쪽의 점도 허용한다. 왼쪽 1·8번은 마진 안쪽이지만 경계의 올바른 쪽이라 마진 위반만 있고, 오른쪽 11·12번은 경계 반대편이라 오분류된다.

Source: James et al. (2023), Figure 9.6.

코드의 C는 위반 비용을 조절한다

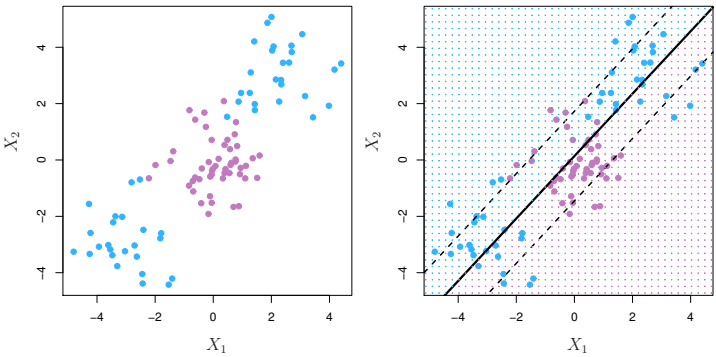
SVC의 C를 키우면 마진 위반에 더 큰 비용을 부과한다

SVC의 C	학습에서 중시하는 것	확인할 것
작다	위반을 감수하고 넓은 마진 확보	경계가 과도하게 단순해지는지
크다	학습 자료의 마진 위반 감소	개별 점에 과도하게 맞추는지

C를 위반 허용량으로 정의하는 식도 있으며, 그 경우 C가 커질 때의 효과는 코드의 C와 반대다.

Source: James et al. (2023), Section 9.2 · scikit-learn SVC documentation.

직선으로 안 되는 자료



왼쪽은 중앙의 보라색 무리와 양쪽의 파란 무리. 오른쪽의 선형 경계는 두 범주 모두에서 많은 점을 오분류

Source: James et al. (2023), Figure 9.8.

선형 커널과 비선형 커널의 역할을 구분한다

선택	원래 특성 공간에서 가능한 경계
선형 커널	초평면
RBF 커널	곡선 형태의 비선형 경계

커널(kernel)은 SVM을 비선형 경계로 확장할 때 사용하는 방법이며 RBF는 그 한 종류

Source: James et al. (2023), Section 9.3.

SVC로 곡선 경계 학습하기

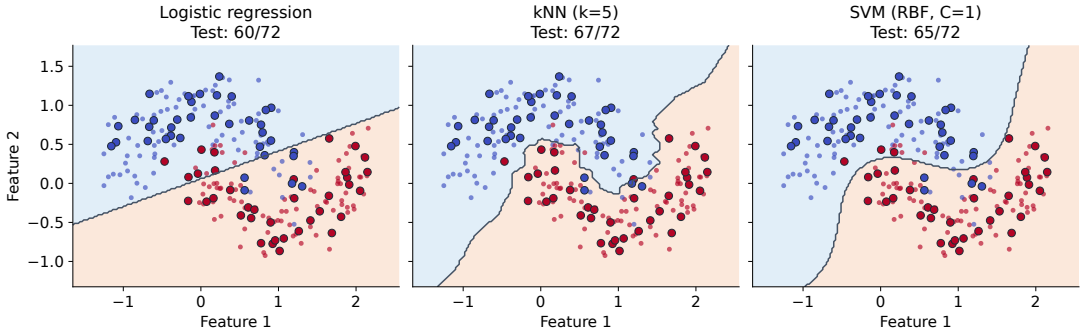
두 반달 모양의 자료 240개를 만들고 30%를 테스트 자료로 남긴다(import 생략)

```
X, y = make_moons(n_samples=240, noise=0.22,
                  random_state=13)
Xtr, Xte, ytr, yte = train_test_split(
    X, y, test_size=0.3, stratify=y, random_state=13)
svm = make_pipeline(StandardScaler(),
                    SVC(C=1, kernel="rbf"))
svm.fit(Xtr, ytr)
pred = svm.predict(Xte)
```

척도 조정은 학습 자료로 적합한다. 테스트 자료에는 같은 변환만 적용한다.

Adapted from scikit-learn (n.d.).

같은 자료에서 세 모델 비교하기



검은 테두리의 점은 테스트 자료 72개다. 세 모델은 동일한 학습 자료 168개로 학습했다. 경계 모양을 보이는 예시이며, 모델 선택은 테스트 점수가 아니라 검증 점수로 한다.

Adapted from scikit-learn (n.d.).

두 방법을 견주면

	kNN	SVM
경계	이웃이 정하는 모양	학습한 결정 함수의 경계
학습	자료를 저장하고 이웃 검색 준비	마진과 위반 비용으로 경계 학습
예측	가까운 이웃을 검색하여 다수결	학습한 결정 함수의 부호
쓰는 점	새 점의 가까운 K개	경계 학습에서 정해진 서포트 벡터

상황에 따라 먼저 비교할 모델

상황	먼저 볼 것	까닭
이웃의 정답 범주가 비슷하다	kNN	국소적인 패턴을 활용한다
직선 경계를 먼저 비교한다	선형 SVM	학습한 계수로 경계를 확인한다
곡선 경계가 필요하다	커널 SVM과 kNN	같은 검증 자료에서 비교한다
예측 시간이 중요하다	두 방법의 실제 실행 시간	관측·서포트 벡터 수가 좌우한다

모델 이름만으로 우열을 정하지 않고 같은 검증 조건에서 비교한다

Checkpoint

Support Vector Machines in Practice

- 마진 위반과 오분류는 어떻게 다른가?
- `SVC`의 C를 키우면 위반 비용은 어떻게 달라지는가?
- 세 모델의 성능을 비교할 때 자료 분할과 척도 조정 조건을 같게 하는 이유는 무엇인가?

Can Distance Alone Draw the Boundary?

Next Lecture: Clustering and Principal Components

- 정답 열이 없을 때 물을 수 있는 것
- 군집 안의 흩어짐을 줄이는 K-means
- 흩어짐이 큰 방향으로 자료를 요약하는 주성분

오용경 yongkyung.oh@pusan.ac.kr