부산대학교
PUSAN NATIONAL UNIVERSITY

Clustering and Components

Structure Without Answers

Grouping Observations and Summarizing Features

BX3600087-140 / DS3600087-140 / AB3600087-140

기계학습개론

2026학년도 2학기

오용경

데이터사이언스전공

yongkyung.oh@pusan.ac.kr

Section 1 • Clustering and Components

Learning Without Labels

정답 열이 없을 때 던질 수 있는 질문을 구분한다

정답 범주 없이 특성만 관측한 자료

주	Murder	Assault	UrbanPop	Rape
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0

USArrests의 첫 세 행. 세 범죄의 인구 10만 명당 체포율과 도시 거주 인구 비율

Source: James et al. (2023), Chapter 12 lab, USArrests.

군집화와 주성분분석은 서로 다른 질문에 답한다

질문	방법	결과
비슷한 관측들을 어떻게 묶을까	군집화	관측별 군집 배정
많은 특성을 적은 축으로 어떻게 요약할까	주성분분석	새 축의 방향과 관측의 좌표

Source: James et al. (2023), Section 12.1.

정답이 없으면 평가 기준을 별도로 정해야 한다

확인 대상	가능한 점검
분류 정확도	정답 범주가 없으면 예측과 대조할 수 없다
군집 내 유사성	설정한 거리와 목적함수로 군집의 응집도를 살핀다
결과의 안정성과 활용	자료·초기값 변화의 영향과 실제 사용 목적을 확인한다

Caution 목적함수 값이 작다는 사실만으로 군집이 실제 범주와 같다고 결론 내릴 수 없다

미리 주어진 범주와 자료에서 찾은 군집

DEFINITION

정답 범주(class)

지도학습에서 관측마다 미리 주어지며 분류 모델이 예측할 대상이 되는 범주

DEFINITION

군집(cluster)

정답 범주를 사용하지 않고 특성의 유사성에 따라 군집화로 찾아낸 관측 집단

군집화(clustering) 결과가 주어진 정답 범주와 일치할 필요는 없다

Checkpoint

Learning Without Labels

- 정답 열이 없으면 왜 정확도를 잴 수 없는가
- 묶기와 요약하기는 각각 무엇을 묻는가
- 군집과 정답 범주는 어떻게 다른가

Section 2 • Clustering and Components

K-means Clustering

군집 안의 흩어짐을 가장 작게 만든다

K-means는 군집 중심까지의 제곱거리를 최소화한다

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \mu_k\|_2^2, \qquad \mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i$$

K-평균 군집화(K-means clustering)는 모든 관측을 K개의 비어 있지 않은 군집으로 겹치지 않게 나눈다. 여기서 K는 군집 수다(kNN의 이웃 수와 다름)

> 순서를 구분한 관측 쌍의 제곱거리 합을 군집 크기로 나누면 이 식의 2배이므로 최소화하는 군집은 같다

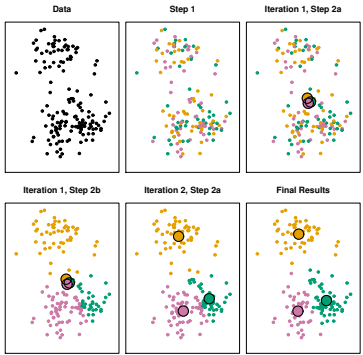
Source: James et al. (2023), Section 12.4.1, Equations 12.17 and 12.18.

두 단계를 번갈아



배정이 더 바뀌지 않을 때까지 뒤의 두 단계를 되풀이한다

반복이 진행되는 모습



색은 군집 배정, 큰 원은 중심점이며 마지막 패널은 10회 반복한 결과

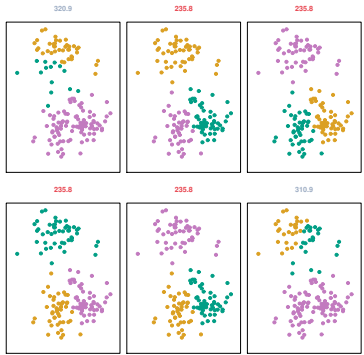
Source: James et al. (2023), Figure 12.8.

두 갱신은 목적함수 값을 늘리지 않는다

갱신	제곱거리 합에 미치는 영향
군집 중심을 평균으로 변경	고정한 배정에서 각 군집의 제곱거리 합을 최소화한다
가장 가까운 중심에 재배정	고정한 중심에서 제곱거리 합이 줄거나 같다
종료 판단	배정이 변하지 않거나 변화가 허용 오차보다 작으면 멈춘다

Caution 값이 늘지 않는다는 사실만으로 유한 단계 종료가 증명되지는 않으며 동률·빈 군집 처리도 정해야 한다

시작점이 답을 바꾼다



같은 자료에 무작위 시작을 여섯 번 준 결과다. 위 숫자는 목적함수 값 320.9, 235.8(네 번), 310.9이며, 빨간 네 결과가 같은 가장 작은 값에 도달했다. 이 값은 앞의 식의 2배 척도다

Source: James et al. (2023), Figure 12.9.

초기값을 바꾸어 얻은 결과의 목적함수를 비교한다

실행 설정	하는 일
한 초기값에서 실행	한 해를 얻지만 그 해가 전역 최적이라는 보장은 없다
여러 초기값에서 실행	같은 자료·같은 K에서 가장 작은 목적함수 값을 선택한다
초기화 횟수	뒤의 USArrests 코드는 `n_init=20`으로 20번 시작해 가장 작은 값을 고른다

기본 설정은 버전에 따라 달라질 수 있으므로 초기화 횟수를 코드에 명시

제곱거리 합만 줄이면 큰 K가 유리해진다

조건	목적함수의 최솟값
K를 늘림	최적 분할의 한 군집을 둘로 나누면 합이 커지지 않으므로 최솟값도 커지지 않는다
관측마다 한 군집	각 관측이 중심과 같으므로 제곱거리 합은 0이다
초기값별 실제 실행 결과	국소해에 멈출 수 있어 실제로 얻은 값은 단조롭게 줄지 않을 수도 있다

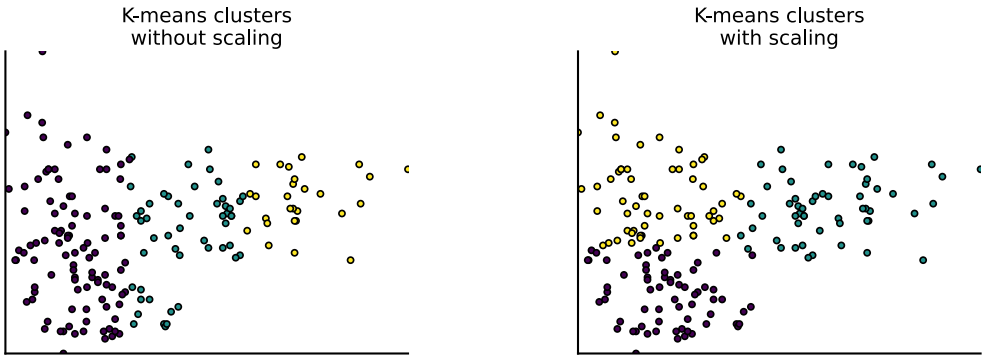
Caution 서로 다른 K를 비교할 때는 적합도뿐 아니라 군집 수와 사용 목적을 함께 본다

특성별 차이의 크기가 군집화에 영향을 준다

입력 표현	거리에서 강조되는 차이
나이는 년, 소득은 원	소득 차이의 제곱이 수치적으로 훨씬 클 수 있다
각 특성을 표준화	특성별 표준편차 단위의 차이를 비교한다
분야 지식에 따른 가중치	사용 목적에 맞는 특성의 차이를 더 반영할 수 있다

척도 조정은 무엇을 비슷하다고 볼지 정하는 모델링 선택이다

척도를 바꾸면 답이 바뀐다



같은 점, 같은 K인데 왼쪽은 세로 띠로, 오른쪽은 비스듬히 나뉜다

Source: scikit-learn MOOC (2022), clustering_quiz_kmeans.

K를 정하는 실제 방법

근거	어떻게 정하는가	쓰는 자리
문제가 정해 준다	나눌 집단 수가 이미 있다	가장 분명한 경우
값이 꺾이는 자리	목적함수가 덜 줄어드는 K	꺾임이 없으면 못 쓴다
결과를 써 본다	군집이 뜻이 통하는지 본다	사람의 판단이 들어간다

Caution 목적함수 곡선은 자료에서 계산하지만 어떤 군집 수를 쓸지는 사용 목적과 함께 판단한다

Checkpoint

K-means Clustering

- 두 단계는 각각 무엇을 계산하는가
- 반복의 종료 조건과 전역 최적의 보장은 어떻게 다른가
- 목적함수 값이 가장 작은 K로 정하면 왜 안 되는가

Principal Components

흩어짐이 가장 큰 방향으로 자료를 요약한다

특성이 많으면 모든 산점도를 비교하기 어렵다

특성 수 p	두 특성씩 짝지은 산점도 수
2	1
4	6
30	435

짝의 수는 $p(p-1)/2$. 적은 축으로 관측을 표현하는 방법을 차원 축소라 하며, 주성분분석(principal component analysis, PCA)이 대표적인 방법이다

첫 주성분은 투영한 값의 분산이 가장 큰 방향이다

$$z_{i1} = \sum_{j=1}^{p} \phi_{j1}(x_{ij} - \bar{x}_j), \qquad \sum_{j=1}^{p} \phi_{j1}^2 = 1, \qquad \phi_1 = \arg\max_{\|\phi\|_2=1} \mathrm{Var}(X_c\phi)$$

특성별 평균을 뺀 뒤 투영하며, ϕ_1은 주성분 축의 방향을 정하는 단위벡터

가장 큰 분산을 보존하는 방향이 정답 범주를 가장 잘 구분하는 방향이라는 보장은 없다

Source: James et al. (2023), Section 12.2.1.

주성분의 방향과 관측의 좌표

DEFINITION

적재량 ϕ

주성분 축의 방향을 정하는 특성별 계수이며, 축 하나마다 특성 수만큼 존재

DEFINITION

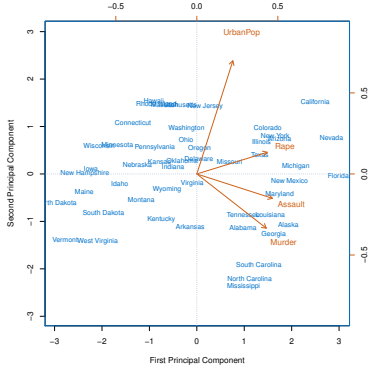
주성분 점수 z

중심화한 관측을 주성분 축에 투영한 좌표이며, 관측마다 축별로 하나씩 계산

적재량(loading)은 축의 정의, 주성분 점수(score)는 그 축에서 관측의 좌표

두 번째 주성분(PC2)은 첫 주성분(PC1)에 직교하는 방향 가운데 분산이 가장 큰 방향이다

한 그림에서 둘을 함께 읽기



파란 주 이름은 아래·왼쪽 축의 점수, 주황 화살표는 위·오른쪽 축의 적재량이다. 두 눈금은 서로 다르다.

오른쪽의 California, Nevada, Florida는 첫 주성분 점수가 커서 범죄율이 높다. 왼쪽의 North Dakota는 범죄율이 낮다.

위쪽의 California는 두 번째 주성분 점수가 커서 도시화가 높고, 아래쪽의 Mississippi는 낮다.

Source: James et al. (2023), Figure 12.1.

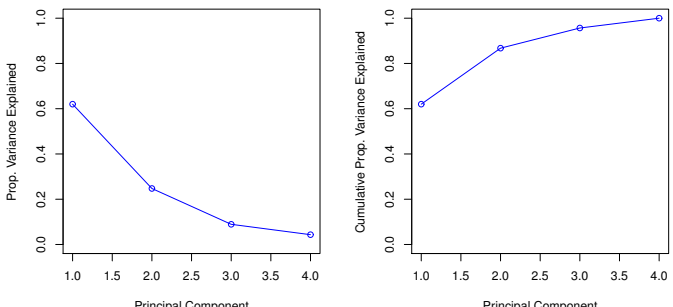
그림의 화살표와 주 이름 위치를 해석한다

보이는 요소	해석
Murder·Assault·Rape 화살표	세 특성이 첫 주성분에 비슷한 크기로 기여하고 UrbanPop의 기여는 작다
UrbanPop 화살표	두 번째 주성분에 큰 양의 적재량을 가진다
오른쪽의 주 이름	해당 주가 첫 주성분의 양의 방향에 위치한다

Caution 두 축의 화살표만으로 원래 네 특성 사이의 관계를 완전히 설명할 수는 없다

남길 주성분 수를 PVE로 비교한다

각 주성분의 설명된 분산 비율(PVE)을 비교한다



왼쪽은 축마다 설명하는 비율, 오른쪽은 앞에서부터 누적한 비율을 보여 준다. 왼쪽 그림을 scree plot(PVE를 주성분 순서로 그린 그림)이라 한다.

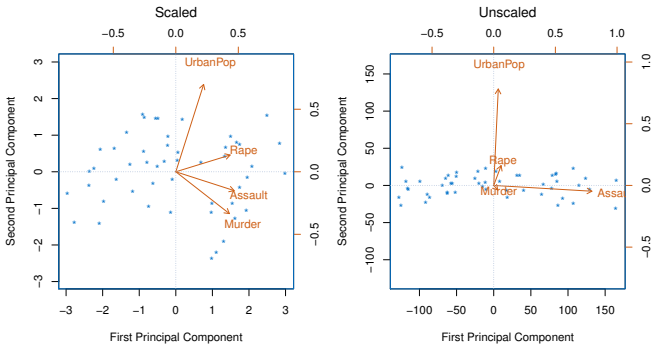
Source: James et al. (2023), Figure 12.3.

PVE로 주성분 수를 고르는 두 규칙

보는 것	고르는 법	한계
축마다의 PVE	갑자기 작아지기 직전까지	눈으로 정한다
누적 PVE	정한 비율을 넘을 때까지	그 비율도 사람이 정한다

Caution PVE 기준은 한 가지 선택 규칙이며 모든 문제에서 같은 개수가 적절하지는 않다

표준화 여부에 따라 주성분의 방향도 달라진다



왼쪽은 특성별 표준편차를 1로 맞춘 결과, 오른쪽은 원래 척도. 오른쪽 PC1에는 Assault의 영향이 크다

Source: James et al. (2023), Figure 12.4.

두 번째 축은 첫 축에 직교하면서 분산을 최대화한다

$$\max_{\phi_2} \mathrm{Var}(X_c\phi_2) \quad \text{subject to} \quad \|\phi_2\|_2 = 1, \quad \phi_1^{\mathsf{T}}\phi_2 = 0$$

X_c는 중심화한 자료 행렬. 첫 축의 조건에 직교 조건이 더해지며, 이후 축도 앞서 정한 모든 축과 직교하도록 선택

주성분 점수는 서로 선형 상관이 없지만 반드시 독립인 것은 아니다

Source: James et al. (2023), Section 12.2.1.

Checkpoint

Principal Components

- 첫 번째 주성분은 어떤 방향으로 정해지는가
- 적재량과 주성분 점수는 각각 무엇마다 하나씩 있는가
- 척도를 맞추지 않으면 첫 축이 왜 달라지는가

Section 4 • Clustering and Components

Putting Them Together

두 방법을 한 작업 흐름에 놓는다

USArrests 분석을 한 번에 재현하기

척도를 맞춘 뒤 주성분 점수 두 개에서 $K = 3$ 군집을 구한다(import 생략)

```
USArrests = pd.read_csv("data/USArrests.csv", index_col="State")
X = StandardScaler().fit_transform(USArrests)
pca = PCA().fit(X)
pve = pca.explained_variance_ratio_   # PVE per PC
phi = pca.components_                 # row m = loading vector
Z = pca.transform(X)                  # PC scores

groups = KMeans(n_clusters=3,
                random_state=3,
                n_init=20).fit_predict(Z[:, :2])
```

scikit-learn의 `KMeans`는 관측을 무작위 배정하는 대신 중심점 *K*개를 골라 시작한다(기본값 k-means++)

Adapted from James et al. (2023), Chapter 12 lab · data: USArrests.

두 축으로 흩어짐의 86.8%를 남겼다

50개 주의 세 범죄 체포율과 도시 거주 인구 비율을 표준화했다

축	PVE	누적 PVE	적재량 절댓값이 큰 특성
PC1	0.620	0.620	Assault 0.583, Rape 0.543, Murder 0.536
PC2	0.247	0.868	UrbanPop 0.873
PC3	0.089	0.957	두 축을 쓸 때 제외
PC4	0.043	1.000	두 축을 쓸 때 제외

PVE는 `pve`, 적재량은 `phi`의 각 행에서 읽은 실행 값이며 표의 적재량은 부호까지 그대로다. 누적 PVE는 반올림 전 값으로 더했다

Source: James et al. (2023), Chapter 12 lab · USArrests.

남길 주성분 수는 보존할 분산과 사용 목적을 함께 본다

판단 기준	선택 방식	주의점
누적 PVE	정한 비율에 도달하는 최소 개수(USArrests: 80%면 2개, 90%면 3개)	분류에 필요한 정보의 보존을 보장하지 않음
PVE 곡선	감소가 완만해지는 지점, USArrests에서는 둘째 축 뒤	뚜렷한 꺾임이 없을 수 있음
후속 활용	시각화 또는 예측 목적에 맞춰 선택	예측용 선택은 검증 자료에서 비교

줄인 축에서 군집화할 때 조심할 것

한 일	생기는 일
축을 너무 적게 남김	버린 방향에 있던 구분이 사라진다
그림에서 군집이 뚜렷함	K-means는 구조가 없는 자료도 K개로 나누므로, 뚜렷해 보이는 경계가 알고리즘이 만든 것일 수 있다
군집에 이름을 붙임	원래 특성의 분포로 그 해석을 뒷받침해야 한다

Caution 두 축에서 보이는 분리가 원래 공간의 차이를 모두 담거나 실제 범주와 일치한다는 보장은 없다

군집 번호를 바꾸어도 같은 분할을 나타낼 수 있다

표현	관측 1	관측 2	관측 3	관측 4
원래 번호	0	0	1	2
번호만 변경	2	2	0	1

설명용 예: 어느 관측들이 함께 묶였는지는 같고 군집을 부르는 번호만 다르다

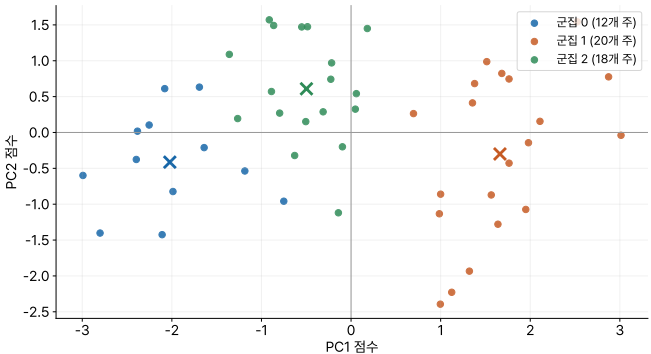
군집 번호를 정답 범주의 숫자와 그대로 대조해 정확도를 계산하면 안 된다

군집화·주성분 결과의 쓰임과 주의점

쓰임	하는 일	주의
살펴보기	자료의 모양을 눈으로 확인	결론이 아니라 출발점
전처리	줄인 축을 모델 입력으로	학습 자료에서만 축을 구한다
해석하기	군집의 특징을 설명	설명은 사람이 붙인 것

> 예측용 전처리에서는 데이터 누수를 막기 위해 자료를 먼저 나누고 학습 자료 안에서만 주성분을 추정한다

두 주성분 평면에서 세 군집이 나뉜다



USArrests 50개 주의 PC1·PC2 점수를 $K = 3$ 군집 색으로 그렸다. ×는 군집 중심이며 번호와 색에는 순서나 뜻이 없다. PC1이 큰 쪽은 세 범죄의 체포율이 높은 주다

Data: James et al. (2023), USArrests.

두 축에서 얻은 세 군집은 크기부터 다르다

실행 결과	값	읽는 법
군집별 주 수	12, 20, 18	번호 자체에는 순서나 뜻이 없다
목적함수 값	54.189	`inertia_`. PC1·PC2 두 축에서 잰 값이므로 같은 차원끼리만 비교한다
사용한 정보	PC1, PC2	제외한 두 축의 분산 13.2%는 사용하지 않는다

Caution 세 군집을 지역 유형이라고 부르려면 원래 특성의 군집별 분포를 따로 확인해야 한다

Data: James et al. (2023), USArrests.

Checkpoint

Putting Them Together

- 줄인 축에서 군집화하면 무엇을 잃을 수 있는가
- 예측용 주성분을 자료 분할 전에 추정하면 왜 데이터 누수가 되는가
- 찾아낸 군집에 이름을 붙이는 일은 누가 하는 것인가

What Can You Learn Without the Answer Column?

Next Lecture: Ensemble Methods

- 나무 한 그루의 예측이 흔들리는 이유
- 부트스트랩 표본과 배깅
- 랜덤 포레스트와 부스팅

오용경 yongkyung.oh@pusan.ac.kr